

面向长期状态预测的 AUV 结构化神经动力学 建模方法

摘要

水下航行器运动建模需要同时处理六自由度刚体运动、强耦合水动力、控制输入和环境扰动。传统参数化动力学模型能够提供清晰的物理解释，但其精度和适用范围依赖水动力参数、工况覆盖和模型校准；完全数据驱动模型具有较强表达能力，却通常缺少对长期递推行为有约束作用的运动结构。为服务于位置、姿态和速度等运动状态的长期预测，本章构造一种 AUV 结构化神经动力学模型。该模型以神经常微分方程为基本形式，将 AUV 运动中的几何约束、能量与耗散结构以及可学习非保守效应组织为受控连续时间动力学假设空间，并简称为 AUVHamNODE。本章通过状态表示和海流条件下的速度变量约定定义受控初值问题，在限定条件下分析静水机械核心的能量平衡，并以长期递推、结构消融、初值扰动和内部物理诊断检验结构约束的作用。本章讨论的端口哈密顿（port-Hamiltonian）性质限定于开放式机械核心及其广义力-速度端口功率平衡；完整航行器-执行器-环境增强系统则作为受控开放系统进行建模和验证。

目录

第一章	面向长期状态预测的 AUV 结构化神经动力学建模方法	2
1.1	研究问题与方法概述	2
1.2	相关建模基础	4
1.2.1	AUV 六自由度运动与功率结构	4
1.2.2	水动力参数获取、校准与闭合困难	5
1.2.3	受控时序预测与连续时间动力学学习	6
1.2.4	科学机器学习与结构化动力学先验	7
1.2.5	哈密顿与端口哈密顿结构的可继承部分	7
1.2.6	从基础到本文方法的落点	9
1.3	受控状态表示与海流速度约定	9
1.3.1	坐标系、状态与控制	9
1.3.2	总体速度与相对水速度	9
1.3.3	数据态、模型态与受控初值问题	10
1.4	结构化连续时间动力学模型	11
1.4.1	SE(3) 运动学	12
1.4.2	相对动量与机械存储函数	12
1.4.3	非保守广义力与执行器通道	13
1.4.4	相对动量动力学	13
1.5	能量平衡与理论边界	14
1.6	训练目标与验证协议	15
1.6.1	结构保持参数化	15
1.6.2	控制块训练目标	15
1.6.3	长期递推与证据口径	16
1.6.4	结构消融设置	17
1.7	讨论	17
1.8	本章小结	18

第一章 面向长期状态预测的 AUV 结构化神经动力学建模方法

1.1 研究问题与方法概述

自主水下航行器 (autonomous underwater vehicle, AUV) 已广泛用于海底测绘、地球物理调查、海洋观测和工程巡检等任务 (Wynn et al., 2014; Sahoo et al., 2019)。在这类任务中, 航行器需要在受控推进、环境扰动和姿态变化共同作用下持续运动。为了支持任务规划、控制器设计、仿真评估和异常诊断, 模型不仅要解释当前运动状态如何变化, 还要能够在给定初始状态、控制输入和环境条件的情况下, 预测未来一段时间内的位置、姿态和速度等运动状态。因此, 本章所讨论的“长期状态预测”不是泛指任意输出的时间序列外推, 而是指受控 AUV 运动状态在长时域内的递推预测。

长期状态预测对运动模型提出了高于短时拟合的要求。短时预测误差主要反映模型对局部状态变化的逼近能力, 而长时域递推会不断把模型输出重新作为后续初值, 使局部误差、姿态偏差和控制响应偏差在轨迹中反复积累。一个模型即使在单个采样间隔内误差较小, 也可能在多步递推后产生明显的位置漂移、姿态不一致或速度发散。因此, AUV 运动建模不能只追求输入-输出函数逼近精度, 还需要关注模型所诱导的运动演化是否与受控动力学的基本约束相容。

传统 AUV 运动建模以参数化六自由度动力学为主线。Fossen 型模型为航行器运动提供了统一的坐标、速度、受力和控制表述, 并已成为仿真、控制和稳定性分析中的重要基础 (Fossen, 2011, 2021)。具体平台模型通常在这一框架下结合平台参数和水动力系数, 形成可计算、可解释的运动系统 (Prestero, 2001)。这类模型的优势在于物理含义清楚, 便于把运动预测、控制设计和工程诊断联系起来。其困难也很明确: 复杂水动力、平台参数和环境扰动往往需要通过计算流体力学、模型试验或系统辨识进行估计, 所得模型的适用范围受工况覆盖、实验成本和数据质量制约 (Phillips et al., 2010; Caccia et al., 2000; Panda et al., 2021; Ahmed et al., 2023)。

数据驱动方法为 AUV 运动建模提供了互补思路。神经网络可以从轨迹数据中学习复杂输入-输出关系, 弱化对完整显式参数模型的依赖, 并可用于状态转移、序列预测或残差动力学建模。已有研究已经将神经网络用于 AUV 导航变量预测、解耦航向和深度响应建模以及物理信息约束的 AUV 动力学学习 (Song et al., 2020; Ertogan and

Wilson, 2024; Zhao et al., 2024)。这类方法说明, 轨迹数据中确实包含可学习的动力学信息; 同时也表明, 仅依靠黑箱映射、局部分量预测或方程残差约束, 仍难以完整回答长期递推中的姿态几何一致性、能量耗散趋势和控制功率组织问题。在短时预测中, 缺少结构约束的数据驱动模型可能仍能取得较小误差; 但在长期状态预测中, 姿态几何、能量耗散趋势和控制作用方式中的不一致会随递推过程被放大。

因此, AUV 数据驱动建模的关键问题不只是如何提高模型容量, 而是如何在可学习模型中保留能够约束长期演化的物理结构。结构化神经动力学为这一目标提供了方法基础。神经常微分方程 (Neural ODE) 通过连续时间向量场描述状态演化, 为受控系统建模和变步长积分提供了自然形式 (Chen et al., 2018); 物理信息机器学习和通用微分方程强调将已知机理与可学习函数结合 (Raissi et al., 2019; Karniadakis et al., 2021; Rackauckas et al., 2020); 哈密顿和端口哈密顿相关神经模型则将能量函数、耗散和输入端口引入学习动力学中 (Greydanus et al., 2019; van der Schaft and Jeltsema, 2014; van der Schaft, 2017)。这些思想并不直接给出完整的 AUV 工程模型, 但它们提供了一条折中路径: 用已知物理关系限制模型假设空间, 同时把难以显式建模的非线性作用留给数据驱动部分表达。

面向 AUV 运动状态的长期递推, 上述通用思想仍需要转化为适合水下航行器的模型形式。一方面, AUV 是受控开放系统, 模型需要描述外部作用对运动状态的影响; 另一方面, AUV 运动具有明确的刚体运动和机械能量背景, 不能简单等同于普通欧氏空间中的黑箱序列。由此产生的研究空缺是: 如何把长期状态预测表述为受控连续时间动力学学习问题, 如何在该学习问题中同时保留位姿几何、机械能量、耗散和输入功率等关键结构, 以及如何用长期递推而非仅用短时误差评价这些结构是否有效。

基于这一问题, 本章提出一种面向长期状态预测的 AUV 结构化神经动力学建模方法。该方法不是构造一个纯黑箱预测器, 也不是声称得到完整闭合的哈密顿或端口哈密顿物理系统; 它的目标是在受控连续时间向量场中组织 AUV 已知运动结构, 并用可学习部分表达难以显式参数化的非线性作用。为行文简洁, 下文将该模型简称为 AUVHamNODE。围绕该目标, 本章关注三个问题: 第一, 如何定义适合海流条件和长期递推的受控状态表示; 第二, 如何把几何、能量、耗散和非保守广义力组织成可训练的结构化向量场; 第三, 如何通过长期递推、结构消融和物理诊断检验结构约束是否真正服务于 AUV 运动状态预测。

上述内容构成本章从问题定义、模型构造到证据检验的论证链。后文首先说明相关建模基础, 再给出受控状态表示、结构化动力学模型和能量平衡边界, 最后说明训练目标与长期递推验证协议。这样的写法不预设方法优势, 而是把模型声称限定在可构造、可分析和可检验的范围内。

1.2 相关建模基础

AUVHamNODE 的模型构造需要同时连接两类语言。第一类来自海洋航行器动力学，它把位置、姿态、体坐标速度、质量、阻尼、恢复力和广义力组织为六自由度运动方程，并给出机械功率账本。第二类来自连续时间学习和结构化神经动力学，它把轨迹预测表述为受控初值问题，并用几何、能量、耗散或端口功率结构限制可学习向量场。本节只保留服务于后文状态约定、模型构造和能量边界的基础内容；具体的数据态、模型态和海流速度契约将在第 1.3 节正式定义。

1.2.1 AUV 六自由度运动与功率结构

AUV 运动通常以惯性坐标系或导航坐标系 n 和航行器体坐标系 b 共同描述。位置 $x \in \mathbb{R}^3$ 在惯性系中表达，姿态可由欧拉角等局部坐标表示，也可由旋转矩阵 $R \in \text{SO}(3)$ 表示。体坐标速度由线速度和角速度组成，记为

$$\nu = \begin{bmatrix} v \\ \omega \end{bmatrix} \in \mathbb{R}^6. \quad (1.1)$$

在局部姿态坐标 $\eta = [x^\top, \vartheta^\top]^\top$ 下，海洋航行器运动学常写为

$$\dot{\eta} = J_\eta(\eta)\nu, \quad (1.2)$$

其中 $J_\eta(\eta)$ 将体坐标速度转换为位置和姿态坐标导数 (Fossen, 2011, 2021)。局部姿态坐标便于与传统控制和仿真框架衔接，但可能引入坐标奇异性或参数化依赖。若直接使用旋转矩阵，则刚体运动学可写为

$$\dot{x} = Rv, \quad \dot{R} = R\hat{\omega}, \quad (1.3)$$

其中 $\hat{\omega} \in \mathfrak{so}(3)$ 是角速度对应的反对称矩阵。该形式使姿态导数位于 $\text{SO}(3)$ 的切空间方向上，体现了旋转群约束本身是机械系统结构信息，而不是普通欧氏状态上的附加正则项 (Bullo and Lewis, 2004; Hairer et al., 2006)。

Fossen 型海洋航行器动力学把 AUV 的惯性、水动力、恢复力和控制作用组织在统一的六自由度方程中 (Fossen, 2011, 2021)。在体坐标速度 ν 下，其常见形式为

$$M\dot{\nu} + C(\nu)\nu + D(\nu)\nu + g(\eta) = \tau, \quad (1.4)$$

其中 $M = M_{\text{RB}} + M_{\text{A}} \succ 0$ 包含刚体质量和附加质量， $C(\nu) = C_{\text{RB}}(\nu) + C_{\text{A}}(\nu)$ 表示刚体与附加质量相关的 Coriolis/向心项， $D(\nu)$ 表示线性或非线性水动力阻尼， $g(\eta)$ 表示重力和浮力恢复项， τ 表示推进器、舵面或外部作用产生的广义力和广义力矩。

式 (1.4) 的价值不只在给出加速度计算公式，更在于它提供了机械功率账本。在标准海洋航行器假设下，若 $C(\nu)$ 满足零功率性质

$$\nu^\top C(\nu)\nu = 0, \quad (1.5)$$

阻尼满足 $D(\nu) \succeq 0$ ，恢复力与势能 $V(\eta)$ 满足功率配对 $\dot{V} = \nu^\top g(\eta)$ ，则机械能

$$H(\eta, \nu) = \frac{1}{2} \nu^\top M \nu + V(\eta) \quad (1.6)$$

在常正定质量矩阵或相应能量配对条件下满足

$$\dot{H} = \nu^\top \tau - \nu^\top D(\nu) \nu. \quad (1.7)$$

这说明质量矩阵定义动能，恢复力对应势能，Coriolis/向心项只重分配动量而不做净功，阻尼消耗机械能，外部广义力通过 $\nu^\top \tau$ 与机械系统交换功率。后文的机械存储函数、耗散分支、零功率耦合和广义力分支均以这一功率角色划分为物理来源。

这一功率账本还区分了控制命令与广义力两个层次。在式 (1.4) 中， τ 已经是进入六自由度动力学的广义力；推进器转速、舵角、控制器输出或期望命令通常还要经过执行器动态、饱和、舵桨效率和流体相互作用，才转化为机械方程中的广义力。因此，后文模型把命令、执行器状态和环境上下文作为广义力分支的条件变量，而不把控制命令本身直接解释为端口哈密顿系统中的功率端口变量。

1.2.2 水动力参数获取、校准与闭合困难

式 (1.4) 中的附加质量、阻尼、恢复力参数和执行器广义力模型通常无法仅由刚体几何直接确定。AUV 水动力系数可通过解析或半经验估计、计算流体力学 (computational fluid dynamics, CFD)、约束模型试验、自由航行试验和系统辨识等路线获得 (Panda et al., 2021; Ahmed et al., 2023)。解析和半经验公式适合早期估计，CFD 可用于比较外形、舵面和推进布局对阻力或控制力的影响 (Phillips et al., 2010)，模型试验能够在特定操纵和速度条件下测量力和力矩，系统辨识则利用实际或仿真输入-输出数据反推参数 (Caccia et al., 2000; Prestero, 2001)。

具体到六自由度模型，需要估计或校准的对象不仅包括纵向、横向和垂向阻尼系数，还包括附加质量矩阵中的耦合项、角速度相关力矩、二次阻力、升力或横流阻力、舵面与推进器产生的控制导数，以及重心和浮心偏置引起的恢复力参数。这些项具有明显的工况依赖性：大攻角、低速操纵、近海底运动、非均匀海流或推进器入流变化都可能改变广义力模型，使同一组名义参数在不同速度、深度或姿态区间表现出不同误差。

不同参数获取路线也有各自边界。CFD 结果受网格、湍流模型、边界条件和计算成本影响，仍需实验或航行数据校准；约束试验覆盖的运动工况有限；自由航行试验更接近实际任务，但会同时混入控制器闭环、传感器误差、执行器非理想性和环境扰动。近年来，AI 辅助水动力系数估计和数据驱动残差建模进一步扩展了传统路线 (Ahmed et al., 2023; Macatangay et al., 2024)。已有工作使用神经网络增强水下航行器模型辨识 (van de Ven et al., 2007)，用支持向量机辨识水下航行器非线性动力学 (Xu et al., 2013)，也用多输出高斯过程进行非参数动力学辨识 (Ariza Ramirez et al., 2021)。这类

方法降低了显式参数化负担，但并不能消除水动力辨识中的非唯一性：同一轨迹误差可能由附加质量、阻尼、舵桨效率、未建模执行器动态、海流估计误差或控制输入偏差的不同组合共同造成。因此，本文后续的神神经分支被解释为结构诱导的非保守广义力假设空间，而不是逐项唯一恢复真实水动力机理。

1.2.3 受控时序预测与连续时间动力学学习

从机器学习角度看，AUV 运动预测可以首先写成受控时序映射。设 s_k 表示离散采样时刻的状态， u_k 表示控制输入， c_k 表示海流、深度或任务上下文，则多步预测可表示为

$$\hat{s}_{k+1:k+H} = \mathcal{F}_\theta(s_{0:k}, u_{0:k+H-1}, c_{0:k+H-1}), \quad (1.8)$$

也可用单步状态转移递推表示为

$$\hat{s}_{k+1} = F_\theta(s_k, u_k, c_k). \quad (1.9)$$

已有 AUV 研究已经利用神经网络处理导航变量预测、运动响应建模、动态定位控制和轨迹预测等问题 (Song et al., 2020; Ertogan and Wilson, 2024; Yao et al., 2024)，物理信息约束也被用于水下航行器动力学学习 (Zhao et al., 2024)。这些工作说明轨迹数据中包含可学习的动力学信息，也说明神经模型可以作为传统建模与控制方法的补充。

离散黑箱时序模型具有训练目标直接、实现成本低和表达能力强等优点，但其局限在长期递推中更加明显。首先，单步转移通常与固定采样间隔绑定，模型学习到的是特定时间步长下的状态映射，而不是独立于采样频率的连续时间向量场。其次，训练阶段常用真实历史状态作为输入，长期验证阶段却必须把预测状态反馈为下一步初值，局部误差会在自由递推中被反复放大。最后，普通离散映射通常不显式区分位置运动学、姿态约束、速度参照系、能量耗散和控制功率；对于 AUV 这类受控机械系统，这些缺失会使短时拟合误差与长时域运动一致性之间出现偏差。

神经常微分方程 (Neural ODE) 将状态演化写成可学习连续时间向量场 (Chen et al., 2018):

$$\dot{y} = f_\theta(y, t), \quad \hat{y}(t) = y(t_0) + \int_{t_0}^t f_\theta(y(\tau), \tau) d\tau. \quad (1.10)$$

对受控 AUV 运动，向量场还必须依赖控制命令、执行器状态或环境上下文，可写为

$$\dot{y} = f_\theta(y(t), u(t), c(t), t), \quad \hat{y}(t_i) = \Phi_\theta(t_i; t_0, y_0, u, c), \quad (1.11)$$

其中 Φ_θ 表示由可学习向量场和输入函数共同诱导的流映射。若外部信号以不规则采样或连续路径形式给出，也可采用 Neural CDE 等路径驱动连续时间模型 (Kidger et al., 2020)；本文后续采用更直接的分段控制块和外源上下文表述。

执行器动态是受控连续时间学习与 AUV 建模结合时必须处理的环节。推进器或舵面命令通常不是瞬时广义力，命令到实际作用之间存在滞后、限幅和非线性映射。将

执行器状态 u_a 纳入增强状态后，可以写成

$$\dot{y}_{\text{mech}} = f_{\theta}(y_{\text{mech}}, u_a, c), \quad \dot{u}_a = f_{\theta}^a(u_a, u_c). \quad (1.12)$$

这种写法使控制命令、执行器状态和实际广义力之间的层级关系可以在连续时间模型中表达，而不是被隐含吸收到单步预测误差中。

神经常微分方程提供的是连续时间学习外壳，本身并不保证物理一致性。给定同一向量场，积分步长、误差容差和求解器类型会影响离散输出；在长期递推中，向量场模型误差、数值积分误差和自由递推误差还会相互放大。因而，若可学习向量场本身没有几何、能量和功率结构，它仍可能产生姿态漂移、速度发散或难以解释的能量变化。

1.2.4 科学机器学习与结构化动力学先验

科学机器学习强调学习型微分方程不应只依赖数据拟合，还应把可信的先验结构写入模型。物理信息神经网络通过方程残差、边界条件和数据项联合训练模型 (Raissi et al., 2019)；物理信息机器学习更广泛地讨论了数据驱动方法与守恒律、对称性和多尺度机理的结合 (Karniadakis et al., 2021)；通用微分方程则把已知微分方程项和未知神经项组合在同一连续时间模型中 (Rackauckas et al., 2020)。在水下航行器场景中，物理信息网络和 physics-guided hybrid 网络已被用于动力学建模和水动力参数辨识 (Zhao et al., 2024; Fei et al., 2026)。这些方法为 AUV 建模提供了重要启发：已知物理关系可以作为模型结构和训练目标的一部分，而难以显式闭合的作用可以由可学习项表达。

不过，对 AUV 长期状态预测而言，通用的方程残差或混合项并不能自动覆盖所有关键结构。首先，姿态变量属于 $\text{SO}(3)$ ，长期递推需要处理旋转群几何一致性。其次，水动力阻尼和非保守作用应与机械能量变化相容，耗散项不应无约束地产生能量。再次，推进器、舵面和外部扰动力矩进入机械方程时应按广义力-速度功率配对解释，而控制命令本身通常还不是功率端口变量。最后，有海流时，位置运动学与水动力广义力依赖的速度口径并不相同；总体速度和相对水速度的区分必须进入状态表示。哈密顿和端口哈密顿结构为这些能量与功率约束提供了更具体的组织方式。

1.2.5 哈密顿与端口哈密顿结构的可继承部分

哈密顿力学以能量函数为中心描述机械系统 (Arnold, 1989)。设 $q \in \mathbb{R}^n$ 为广义坐标， $p \in \mathbb{R}^n$ 为共轭动量。对典型机械系统，哈密顿量可写为

$$H(q, p) = \frac{1}{2} p^{\top} M(q)^{-1} p + V(q), \quad \frac{\partial H}{\partial p} = M(q)^{-1} p. \quad (1.13)$$

在正则坐标中，哈密顿方程具有斜对称结构

$$\dot{z} = J \nabla H(z), \quad J = -J^{\top}, \quad (1.14)$$

其中 $z = [q^\top, p^\top]^\top$ 。由于 J 斜对称, 连续时间精确流满足 $\dot{H} = \nabla H^\top J \nabla H = 0$ 。因此, 能量守恒不是由“存在一个标量函数”单独产生的, 而是由能量梯度和斜对称互连结构共同产生的。

哈密顿神经网络 (Hamiltonian Neural Network, HNN) 将这一思想用于神经动力学学习 (Greydanus et al., 2019): 模型不直接拟合任意 $\dot{z}$, 而是学习标量能量函数 $H_\theta(z)$, 再由结构方程生成向量场。后续 SymODEN 和 Dissipative SymODEN 进一步把控制、耗散和不可直接观测动量纳入结构化学习框架 (Zhong et al., 2020b,a)。对 AUV 建模而言, 可继承的不是闭合保守系统的能量守恒假设, 而是“机械存储函数 + 受限结构生成向量场”的建模原则; AUV 本身是受控开放系统, 存在阻尼、推进器和舵面输入、海流影响、执行器滞后以及环境扰动。

端口哈密顿系统把哈密顿能量方法扩展到开放、耗散和受控系统 (van der Schaft and Jeltsema, 2014; van der Schaft, 2017)。有限维端口哈密顿系统常写为

$$\dot{z} = (J(z) - R(z))\nabla H(z) + G(z)u, \quad J(z) = -J(z)^\top, \quad R(z) \succeq 0. \quad (1.15)$$

若定义端口输出 $y = G(z)^\top \nabla H(z)$, 则存储函数满足

$$\dot{H} = -\nabla H(z)^\top R(z) \nabla H(z) + y^\top u \leq y^\top u. \quad (1.16)$$

该不等式说明, 内部耗散不会自行增加存储能量, 能量增加必须通过外部端口功率解释。与 HNN 的保守情形不同, 端口哈密顿形式不要求能量守恒, 而要求能量变化的来源在功率账本中可追踪。

机械系统的端口哈密顿形式与 Fossen 型功率结构存在自然联系: 动量变量下的机械存储函数给出速度映射, Coriolis/向心项可解释为零功率互连的一部分, 阻尼对应耗散, 推进器和舵面产生的广义力对应外部机械端口。因此, 式 (1.7) 可理解为海洋航行器动力学中的端口哈密顿风格功率平衡。但这一联系具有明确边界: 实际 AUV 模型还包含经验舵桨项、执行器限幅、控制器闭环、海流外源和未建模环境扰动。若没有为这些部分引入额外状态、端口和储能定义, 就不能把完整航行器-执行器-环境增强系统声称为闭合标准端口哈密顿系统。

端口哈密顿神经模型或 pH 风格神经模型把 H 、 J 、 R 或 G 中的部分对象参数化为神经网络, 同时保留斜对称、正定耗散和端口功率结构。相关综述指出, 机器学习与端口哈密顿系统的结合主要围绕哈密顿学习、结构保持降阶、pH 实现和控制展开 (Cherifi, 2020)。已有 pHNN 和伪哈密顿神经模型还强调了外部力与内部结构的分离: 显式时变受迫系统和状态相关外部力都可以在哈密顿/pH 风格框架中建模 (Desai et al., 2021; Eidnes et al., 2023)。本文采用这些思想构造结构化连续时间假设空间, 但只把可证明的端口语义限定在开放式机械核心及其广义力-速度功率配对上; 执行器状态、海流外源和由上下文驱动的非线性广义力分支将在后文作为受控开放系统的一部分处理。

1.2.6 从基础到本文方法的落点

上述基础给出本文方法的三个落点。首先, Fossen 型六自由度动力学提供了 AUV 运动中的功率账本, 但复杂水动力、执行器作用和环境扰动使完整参数化模型难以在所有工况下闭合。其次, 神经常微分方程将轨迹预测表述为受控连续时间初值问题, 适合长期递推和不同控制块长度下的动力学学习, 但非结构化向量场本身不保证姿态几何、能量耗散和功率配对的一致性。最后, 哈密顿和端口哈密顿思想提供了机械存储、耗散、零功率互连和外部功率端口的组织方式, 但这些结构必须限定在可定义、可分析的机械核心内使用。

因此, 后文首先定义数据态与模型态之间的速度口径, 特别是海流条件下总体速度和相对水速度的关系; 随后构造融合 SE(3) 运动学、相对动量、机械存储函数、耗散和非保守广义力的连续时间模型; 最后在限定条件下分析机械核心的能量平衡, 并用训练和长期递推验证协议检验结构约束是否服务于 AUV 运动状态预测。

1.3 受控状态表示与海流速度约定

1.3.1 坐标系、状态与控制

设 n 表示惯性坐标系或导航坐标系, b 表示航行器体坐标系。航行器配置变量定义为

$$q = (x, R), \quad x \in \mathbb{R}^3, \quad R \in \text{SO}(3), \quad (1.17)$$

其中 x 表示惯性系位置或控制块内以初始位置为原点的相对位置, R 将体坐标系向量映射到惯性坐标系。体坐标系角速度记为 $\omega \in \mathbb{R}^3$ 。执行器命令记为 $u_c \in \mathbb{R}^m$, 实际执行器状态记为 $u_a \in \mathbb{R}^m$ 。二者具有不同物理含义: u_c 是控制器或数据集给出的命令, u_a 是经过执行器动态后的内部状态, 并作为广义力分支的输入之一。

一个训练或验证控制块由采样时刻 $\{t_i\}_{i=0}^T$ 上的状态序列组成。数据空间保存可观测或可重建的轨迹状态, 本文记为

$$s_i = [x_i, \text{vec}(R_i), \nu_{b,i}, u_{a,i}, u_{c,i}, v_{c,i}^n, z_{\text{ref}}] \quad (1.18)$$

表示。这里 $v_c^n \in \mathbb{R}^3$ 为惯性系海流速度, $z_{\text{ref}} \in \mathbb{R}$ 为可选深度上下文; 无海流数据可令 $v_c^n = 0$, 无绝对深度上下文的数据可省略 z_{ref} 。向量化符号 $\text{vec}(R)$ 仅表示存储格式; 数学上姿态变量仍受 $R \in \text{SO}(3)$ 约束。数据态 s_i 的速度槽采用总体速度口径, 其物理含义由下一小节给出。

1.3.2 总体速度与相对水速度

有海流时, 航行器相对于惯性系的总体速度与相对于周围水体的速度不同。总体速度描述航行器位姿在惯性系中的变化; 相对水速度描述航行器相对于局部水体的运

动, 直接影响阻尼、升力和横向水动力等非保守广义力。令惯性系海流速度为 $v_c^n \in \mathbb{R}^3$, 则体坐标系海流速度为

$$v_c^b = R^\top v_c^n. \quad (1.19)$$

数据空间中的体坐标系总体速度记为

$$\nu_b = \begin{bmatrix} v_b \\ \omega \end{bmatrix}, \quad (1.20)$$

其中 $v_b \in \mathbb{R}^3$ 是航行器相对于惯性系运动的体坐标系线速度, $\omega \in \mathbb{R}^3$ 是体坐标系角速度。模型内部用于水动力相关广义力计算的相对水速度记为

$$\nu_r = \begin{bmatrix} v_r \\ \omega \end{bmatrix}, \quad v_r = v_b - v_c^b. \quad (1.21)$$

海流只平移线速度分量, 不改变体坐标系角速度。因此, 数据空间和模型空间之间的速度契约为

$$\nu_r = \nu_b - \begin{bmatrix} R^\top v_c^n \\ 0 \end{bmatrix}, \quad \nu_b = \nu_r + \begin{bmatrix} R^\top v_c^n \\ 0 \end{bmatrix}. \quad (1.22)$$

无海流时可取 $v_c^n = 0$, 式 (1.22) 退化为 $\nu_r = \nu_b$ 。上述变量关系保证位置运动学和水动力建模使用各自适合的速度口径: 位置 x 相对于惯性系变化, 因此由总体速度推进; 阻尼、升力、横向耦合和执行器相关水动力主要依赖航行器相对于水体的运动, 因此由相对水速度参数化。对应的位置运动学可写为

$$\dot{x} = Rv_b = R(v_r + R^\top v_c^n) = Rv_r + v_c^n. \quad (1.23)$$

式 (1.23) 只说明线速度口径的转换; 完整的姿态运动学和相对动量动力学在下一节的模型构造中给出。




图 1.1: 海流条件下数据态、模型态与输出态之间的速度变量关系。数据空间保留总体速度, ODE 模型空间使用相对水速度, 输出评估前再恢复总体速度。

1.3.3 数据态、模型态与受控初值问题

训练数据保存总体速度口径下的状态

$$s = [x, R, \nu_b, u_a, u_c, v_c^n, z_{\text{ref}}], \quad s \in \mathcal{S}_d, \quad (1.24)$$

ODE 求解器内部使用相对水速度口径下的增强状态

$$y = [x, R, \nu_r, u_a, u_c, v_c^n, z_{\text{ref}}], \quad y \in \mathcal{S}_m. \quad (1.25)$$

其中 $\mathcal{S}_d$ 和 $\mathcal{S}_m$ 分别表示数据态空间和模型态空间；二者在位置、姿态、执行器状态、命令和外源上下文上共享同一数值，只在线速度口径上不同。为简化记号，定义

$$\Delta_c(R, v_c^n) = \begin{bmatrix} R^\top v_c^n \\ 0 \end{bmatrix}. \quad (1.26)$$

则数据态到模型态的映射为

$$\mathcal{T}_{d \rightarrow m}(s) = [x, R, \nu_b - \Delta_c(R, v_c^n), u_a, u_c, v_c^n, z_{\text{ref}}], \quad (1.27)$$

模型态到数据态的映射为

$$\mathcal{T}_{m \rightarrow d}(y) = [x, R, \nu_r + \Delta_c(R, v_c^n), u_a, u_c, v_c^n, z_{\text{ref}}]. \quad (1.28)$$

图 1.1 概括了这两个映射及其物理使用口径。

由此，受控轨迹预测任务可表述为一个带状态转换的连续时间初值问题。给定初始数据态 s_0 、控制块内的命令 u_c 和外源上下文 $c = (v_c^n, z_{\text{ref}})$ ，先将初值转换为模型态

$$y_0 = \mathcal{T}_{d \rightarrow m}(s_0). \quad (1.29)$$

神经常微分方程在模型态空间中产生连续时间流

$$\hat{y}(t_i) = \Phi_\theta(t_i; t_0, y_0, u_c, c), \quad i = 0, \dots, T, \quad (1.30)$$

再通过输出映射回到数据空间

$$\hat{s}_i = \mathcal{T}_{m \rightarrow d}(\hat{y}(t_i)). \quad (1.31)$$

训练损失和评估指标在观测时刻比较 $\hat{s}_i$ 与真实数据态 s_i 。因此，位置、姿态、总体速度和执行器状态等可观测量始终在数据空间解释；相对水速度则作为模型空间变量，用于水动力建模和内部诊断。该约定使后续 SE(3) 运动学、机械能模型、训练损失和长期 rollout 指标使用一致的状态口径。

1.4 结构化连续时间动力学模型

前文给出了本章方法的两个来源。受控时序预测表述提供了从轨迹数据中学习复杂非线性动力学的形式基础，但普通离散模型和非结构化 Neural ODE 缺少几何与能量结构；Fossen 型动力学和端口哈密顿表述提供了质量、Coriolis、阻尼、恢复力和输入功率之间的角色划分，但实际工程模型通常包含半经验项、执行器动态和环境外源。AUVHamNODE 的目标是在连续时间可学习向量场中保留这些关键结构，并将无法解析闭合的非保守效应交由受约束的神经参数化表达。

AUVHamNODE 在连续时间神经向量场中嵌入以下约束：

1. 位姿演化遵循 SE(3) 刚体运动学；
2. 机械能由正定质量矩阵和标量势能函数定义；
3. 非保守广义力分解为正定耗散、斜对称零功率耦合和可学习外部广义力；
4. 控制命令通过执行器状态进入广义力分支；
5. 环境外源作为状态上下文参与速度转换和广义力计算。

这些约束使模型处于传统物理模型和非结构化深度模型之间：它不要求所有水动力项可解析辨识，也不放弃机械系统的基本结构。

1.4.1 SE(3) 运动学

AUVHamNODE 显式编码刚体位姿运动学：

$$\dot{x} = Rv_b, \quad \dot{R} = R\hat{\omega}. \quad (1.32)$$

其中 $\hat{\omega} \in \mathfrak{so}(3)$ 表示角速度 ω 对应的反对称矩阵。式 (1.32) 将姿态导数限制在旋转群的切空间方向上。当存在海流外源时， $v_b = v_r + R^\top v_c^n$ ，因此

$$\dot{x} = R(v_r + R^\top v_c^n) = Rv_r + v_c^n. \quad (1.33)$$

连续时间层面，若 $R(0) \in \text{SO}(3)$ ，则 $\dot{R} = R\hat{\omega}$ 与 $\text{SO}(3)$ 的切空间相容。若实际数值实现采用普通 ODE 求解器对旋转矩阵元素积分，则离散数值解仍可能出现正交性漂移，因此评估中需要同时报告姿态误差与 $\text{SO}(3)$ 正交性诊断。

1.4.2 相对动量与机械存储函数

模型使用相对水速度定义相对动量

$$p_r = M_\theta v_r, \quad (1.34)$$

其中 $M_\theta \in \mathbb{R}^{6 \times 6}$ 为正定质量矩阵。机械存储函数定义为

$$H_\theta(q, p_r) = \frac{1}{2} p_r^\top M_\theta^{-1} p_r + V_\theta(q), \quad (1.35)$$

其中 $V_\theta(q)$ 为标量势能函数。该写法继承 Fossen/pH 结构中的能量账本，使保守广义力与同一个标量存储函数相关。

1.4.3 非保守广义力与执行器通道

水动力阻尼、升力、执行器作用和未建模效应通过非保守广义力进入相对动量力学。模型将该部分写为

$$f_{\theta}^{\text{nc}} = -D_{\theta}(\xi)\nu_r + J_{\theta}(\xi)\nu_r + \tau_{\theta}(\nu_r, u_a, c), \quad (1.36)$$

其中 $D_{\theta}(\xi) \succeq 0$ 表示耗散矩阵, $J_{\theta}(\xi) = -J_{\theta}(\xi)^{\top}$ 表示斜对称零功率耦合矩阵, τ_{θ} 表示由执行器状态和上下文驱动的可学习广义力分支。条件变量 ξ 表示耗散和零功率耦合分支可使用的运动特征; 在基本情形下 $\xi = \nu_r$, 在海流扩展中可加入体坐标海流速度 v_c^b 或总体线速度 v_b 。该分解是物理诱导的功能分解, 不保证唯一恢复真实水动力项。

执行器命令 u_c 不直接等同于实际广义力。实际执行器状态满足

$$\dot{u}_a = T_{\theta}^{-1}(u_c - u_a), \quad \dot{u}_c = 0, \quad (1.37)$$

其中 $T_{\theta} \in \mathbb{R}_{>0}^m$ 为正时间常数。环境外源在单个积分窗口内作为上下文携带, 例如

$$\dot{v}_c^n = 0. \quad (1.38)$$

该通道用于状态转换和可选广义力条件特征。本章模型将环境场作为外源上下文处理, 而非闭合哈密顿环境子系统。

1.4.4 相对动量动力学

综合运动学、势能梯度和非保守广义力, 模型在相对动量变量上构造连续时间向量场:

$$\dot{p}_r = \text{ad}_{\nu_r}^* p_r + f_{\theta}^V(q) + f_{\theta}^{\text{nc}}, \quad (1.39)$$

令 $p_r = [p_v^{\top}, p_{\omega}^{\top}]^{\top}$, $\nu_r = [v_r^{\top}, \omega^{\top}]^{\top}$ 。本章采用的体坐标动量耦合项可写为

$$\text{ad}_{\nu_r}^* p_r = \begin{bmatrix} p_v \times \omega \\ p_{\omega} \times \omega + p_v \times v_r \end{bmatrix}. \quad (1.40)$$

该式给出本章使用的 ad^* 符号约定, 并满足

$$\nu_r^{\top} \text{ad}_{\nu_r}^* p_r = v_r^{\top} (p_v \times \omega) + \omega^{\top} (p_{\omega} \times \omega + p_v \times v_r) = 0, \quad (1.41)$$

因而该项只改变体坐标动量分量之间的耦合, 不改变机械存储能量。势能诱导的保守广义力 $f_{\theta}^V(q)$ 由 V_{θ} 的自动微分梯度构造。若将 $R_{i:}$ 记为 R 的第 i 行, $\partial V_{\theta}/\partial R_{i:}$ 记为对应行梯度, 则可写为

$$f_{\theta}^V(q) = \begin{bmatrix} -R^{\top} \nabla_x V_{\theta}(q) \\ \sum_{i=1}^3 R_{i:} \times \frac{\partial V_{\theta}(q)}{\partial R_{i:}} \end{bmatrix}. \quad (1.42)$$

在静水条件下, $\dot{x} = Rv_r$ 、 $\dot{R} = R\hat{\omega}$, 式 (1.42) 满足

$$\nu_r^\top f_\theta^V(q) = -\frac{d}{dt}V_\theta(q). \quad (1.43)$$

该配对关系是后文能量平衡命题成立的关键条件。质量矩阵为常矩阵时, 相对速度导数由

$$\dot{\nu}_r = M_\theta^{-1}\dot{p}_r \quad (1.44)$$

给出。

1.5 能量平衡与理论边界

定义 1.1 (AUVHamNODE 的机械核心). 在给定外部广义力 $\tau_\theta(\nu_r, u_a, c)$ 的条件下, AUVHamNODE 的机械核心指由配置 $q = (x, R)$ 、相对动量 p_r 、机械存储函数 $H_\theta(q, p_r)$ 、SE(3) 运动学、保守广义力 $f_\theta^V(q)$ 、正定耗散项 $-D_\theta(\xi)\nu_r$ 和斜对称零功率耦合项 $J_\theta(\xi)\nu_r$ 组成的连续时间力学子系统。执行器状态 u_a 、命令 u_c 、海流 v_c^n 和深度上下文 z_{ref} 属于增强状态或外源上下文; 它们可以影响广义力分支或速度转换, 但不作为机械存储函数的独立储能变量。因而, 本章的端口哈密顿性质只针对该机械核心的功率平衡, 而不针对完整增强状态作闭合系统声明。

命题 1.1 (静水机械核心的能量平衡). 考虑无海流或静水条件 $v_c^n = 0$ 。假设连续时间精确流满足 $R(t) \in \text{SO}(3)$ 、 $M_\theta \succ 0$ 且 M_θ 不随状态变化、 $D_\theta(\xi) \succeq 0$ 、 $J_\theta(\xi) = -J_\theta(\xi)^\top$, 体坐标动量耦合项满足式 (1.40) 的零功率配对, 且保守广义力满足式 (1.43)。对于机械存储函数 (1.35) 和非保守力分解 (1.36), 机械核心满足

$$\dot{H}_\theta = -\nu_r^\top D_\theta(\xi)\nu_r + \nu_r^\top \tau_\theta(\nu_r, u_a, c). \quad (1.45)$$

特别地, 当 $\tau_\theta = 0$ 时, 机械核心的存储能量非增。

证明. 机械存储函数可分解为动能 $K_\theta = \frac{1}{2}p_r^\top M_\theta^{-1}p_r$ 和势能 $V_\theta(q)$ 。由于 M_θ 为常正定矩阵, 且 $\partial H_\theta / \partial p_r = M_\theta^{-1}p_r = \nu_r$, 动能导数为

$$\dot{K}_\theta = \nu_r^\top \dot{p}_r. \quad (1.46)$$

将式 (1.39) 代入, 得到

$$\dot{K}_\theta = \nu_r^\top \text{ad}_{\nu_r}^* p_r + \nu_r^\top f_\theta^V(q) + \nu_r^\top f_\theta^{\text{nc}}. \quad (1.47)$$

由式 (1.40) 的零功率性质, 第一项为零; 由势能功率配对式 (1.43), 第二项等于 $-\dot{V}_\theta$ 。因此

$$\dot{H}_\theta = \dot{K}_\theta + \dot{V}_\theta = \nu_r^\top f_\theta^{\text{nc}}. \quad (1.48)$$

再代入式 (1.36), 有

$$\nu_r^\top \dot{f}_\theta^{\text{nc}} = -\nu_r^\top D_\theta(\xi) \nu_r + \nu_r^\top J_\theta(\xi) \nu_r + \nu_r^\top \tau_\theta(\nu_r, u_a, c). \quad (1.49)$$

由于 $J_\theta(\xi) = -J_\theta(\xi)^\top$, $\nu_r^\top J_\theta(\xi) \nu_r = 0$, 从而得到式 (1.45)。又因 $D_\theta(\xi) \succeq 0$, 当 $\tau_\theta = 0$ 时有 $\dot{H}_\theta \leq 0$ 。□

该命题刻画的是机械核心在限定条件下的连续时间功率平衡, 并不表示普通数值积分过程严格保持该等式。完整增强模型还包含执行器滞后和环境外源, 且 τ_θ 是由执行器状态与上下文条件化的广义力端口, 因而本章将完整系统作为受控开放系统处理。有外源流场时, 若势能依赖绝对位置或深度, 能量导数还可能包含由外源平移引入的附加功率项。

1.6 训练目标与验证协议

1.6.1 结构保持参数化

神经参数化服务于上述理论对象, 并将部分结构性质直接写入可训练函数类。逆质量矩阵采用 Cholesky 型参数化: 令 L_M 为下三角矩阵, 其对角元由 softplus 映射保证为正, 则

$$M_\theta^{-1} = L_M L_M^\top \succ 0, \quad M_\theta = (M_\theta^{-1})^{-1}. \quad (1.50)$$

势能分支输出标量 $V_\theta(q)$, 实际实现中可使用重力方向、姿态特征和可选绝对深度上下文作为输入。耗散分支在完整形式下输出下三角因子 $L_D(\xi)$, 并构造

$$D_\theta(\xi) = L_D(\xi) L_D(\xi)^\top \succeq 0; \quad (1.51)$$

对角阻尼消融则使用正对角元素构造 $\text{diag}(d_\theta(\xi))$ 。斜对称分支输出矩阵上三角参数并反对称化:

$$J_\theta(\xi) = A_\theta(\xi) - A_\theta(\xi)^\top. \quad (1.52)$$

可学习广义力分支 τ_θ 接收执行器状态、相对速度和可选海流特征, 用于表达执行器驱动和其他无法解析闭合的非保守广义力。

上述参数化将正定性、半正定性和斜对称性直接作用于可训练函数类。由参数化直接保证的性质构成模型结构约束; 由数值积分、状态转换和数据分布共同决定的性质, 则通过训练目标和评估指标进行检验。

1.6.2 控制块训练目标

训练数据由控制块序列组成。在单个控制块内, 控制命令和外源上下文保持分段常值, 模型从块初值出发积分生成预测轨迹。预测过程为

$$y_0 = \mathcal{T}_{d \rightarrow m}(s_0), \quad \hat{y}(t_i) = \Phi_\theta(t_i; t_0, y_0, u_c, c), \quad \hat{s}_i = \mathcal{T}_{m \rightarrow d}(\hat{y}(t_i)), \quad (1.53)$$

表 1.1: 理论对象与可训练参数化的对应关系

理论对象	参数化目标	结构作用
M_θ^{-1}	$L_M L_M^\top$ 正定逆质量矩阵	保证动能二次型正定，定义相对动量和速度映射。
$V_\theta(q)$	标量势能网络与线性先验	使保守广义力来自同一能量函数。
$D_\theta(\xi)$	满矩阵正定阻尼或对角正阻尼	保证耗散项不向机械核心注入能量。
$J_\theta(\xi)$	反对称化耦合矩阵	表达零功率横向或升力类耦合。
$\tau_\theta(\nu_r, u_a, c)$	执行器状态和上下文驱动的广义力网络	表达执行器驱动和未建模非保守效应；不等同于标准 $G(q)u$ 端口矩阵。
T_θ	softplus 正时间常数	表达命令到实际执行器状态的一阶滞后。
$\mathcal{T}_{d \rightarrow m}, \mathcal{T}_{m \rightarrow d}$	数据/模型状态转换	维持输出空间和内部动力学变量的一致性。

其中 Φ_θ 表示由神经常微分方程积分得到的流映射。训练时，目标轨迹也转换到模型态 $y_i = \mathcal{T}_{d \rightarrow m}(s_i)$ ，使有海流样本的速度损失作用于相对水速度口径；位置、姿态和执行器状态在数据态与模型态中保持同一数值。一个典型加权训练目标可写为

$$\mathcal{L} = \sum_i \lambda_x \|\hat{x}_i - x_i\|^2 + \lambda_R d_{\text{SO}(3)}(\hat{R}_i, R_i)^2 + \lambda_\nu \|\hat{\nu}_{r,i} - \nu_{r,i}\|^2 + \lambda_a \|\hat{u}_{a,i} - u_{a,i}\|^2 + \lambda_{\text{SO}} \mathcal{L}_{\text{SO}(3)}, \quad (1.54)$$

其中 $d_{\text{SO}(3)}$ 为旋转测地距离， $\mathcal{L}_{\text{SO}(3)}$ 为旋转矩阵正交性和行列式正则项。评估和报告时，预测轨迹再通过 $\mathcal{T}_{m \rightarrow d}$ 回到数据态，因此终端位置、姿态和总体速度等可观测指标仍在数据空间解释。

1.6.3 长期递推与证据口径

评估协议的目标不是只比较局部拟合误差，而是检验结构约束是否改善长期递推稳定性、初值扰动鲁棒性和内部物理一致性。数据来源采用受控仿真生成的 AUV 轨迹块，可区分无海流和有海流设置；有海流数据使用式 (1.22) 明确总体速度与相对水速度的转换关系。训练设置至少区分干净初值训练 (clean training) 与基于噪声配置的初值扰动训练 (profile-based noisy initial-condition training)，后者通过预热、斜坡增长和干净样本混合比例控制训练噪声强度。

长期递推预测将上一控制块的预测末状态作为下一控制块初值，用于检验误差累积、姿态漂移、速度发散和数值失败。该任务的首要指标是完成率 (completion rate)、到达目标时域完成率 (completed-to-horizon rate) 和失败原因 (failure reason)，因为

只有模型完成目标时域后，终端误差才具有可比性。失败原因应区分预测发散、ODE 求解失败、NaN/Inf、速度或深度约束违反，以及地面真值递推任务自身失败等情形。

在完成目标时域的样本上，主要误差指标包括终端位置误差、深度误差、旋转测地误差、总体线速度误差、总体角速度误差和误差增长曲线；可进一步报告中位数、第 90 百分位或第 95 百分位轨迹误差以展示长期误差累积。相对速度误差属于模型空间诊断，用于解释水动力建模变量是否一致，不替代数据空间总体速度指标。能量、SO(3) 行列式误差和正交性误差用于解释内部结构是否按预期工作，也不替代外部任务误差。

可复现实验报告需要同时给出数据生成配置、训练/验证/测试划分、随机种子、控制块长度、采样间隔、积分器类型、误差容差、长期递推时域、失败判据、噪声配置和代码环境记录。结果进入主结论前应满足一致的数据协议、评估口径和代码环境记录。目录化结果可优先使用规范化长期递推结果视图生成表格和图，但规范化视图不自动等于当前论文证据；引用具体数值时还需检查证据状态。标记为证据过期、需要复核或仅具有协议敏感性分析含义的结果，只能用于讨论证据边界、协议敏感性或后续工作，不能作为主性能排序的无条件依据。

1.6.4 结构消融设置

模型比较链条覆盖非结构化 full-state 模型、SE(3) 加速度模型、SE(3) 动量模型、端口哈密顿风格结构模型和 AUVHamNODE 完整模型。该链条用于分离几何运动学、动量坐标、能量结构和非保守力分解各自的作用。结构消融对象包括质量先验、耦合阻尼、斜对称零功率耦合、广义力分支条件化方式以及非保守力合并方式。

1.7 讨论

本章方法的端口哈密顿性质限定于开放式机械核心及其功率平衡，不等同于完整航行器-执行器-环境系统的严格闭合端口哈密顿化。执行器状态、命令输入、海流和深度上下文属于增强状态或外源上下文，它们可以条件化广义力分支或参与速度转换，但不作为机械存储函数中的独立储能变量。因此，本章的理论声明应理解为对结构化连续时间向量场和机械核心功率账本的约束，而不是对完整增强系统的闭合能量守恒声明。

连续时间向量场与 SO(3) 切空间相容，但若数值实现采用普通 ODE 求解器，仍可能产生离散积分层面的正交性误差。因而，姿态预测不能只报告欧氏矩阵误差，还需要报告旋转测地误差、行列式偏差和正交性诊断。若后续采用严格李群积分器或投影积分方案，可进一步区分模型结构误差和数值积分误差。

非保守力分解提供结构诱导的功能角色，不保证唯一辨识真实水动力项。正定耗散、斜对称零功率耦合和可学习广义力分支可以提高假设空间的可解释性，但不同分支之间仍可能存在统计补偿。结构消融和内部物理诊断只能说明这些结构在给定数据

表 1.2: 模型比较与结构消融的证据角色

模型类别	代表模型	证据作用
非结构化状态模型	Full-State Black-Box	检验缺少几何与能量结构时的长期递推风险。
几何基线	SE(3) Acceleration Black-Box	隔离显式位姿运动学对姿态和位置预测的作用。
动量基线	SE(3) Momentum Black-Box	隔离动量坐标和质量矩阵对速度预测的作用。
结构化 pH 基线	pH NODE Merged Force, pH NODE q-Force	检验能量核心和不同广义力组织方式的贡献。
完整模型	AUVHamNODE / pH NODE Full	同时包含速度契约、SE(3) 运动学、机械存储、 $D/J/\tau$ 分解和执行器滞后。
消融模型	No Mass Prior, Diagonal Damping, No Lift, B(u) Only	分别检验质量先验、耦合阻尼、零功率耦合和执行器条件化的必要性。

协议和模型族下的作用，不能单独证明各神经分支逐项恢复了真实物理机理。

当前实验验证对象是受控仿真生成的数据分布。仿真数据能够提供可重复、可消融和可诊断的证据环境，但不等同于真实海试条件下的泛化验证。真实海域中的传感器偏差、海况变化、平台参数误差、执行器非理想性和未建模环境扰动仍需要后续实验支持。基于噪声配置的初值扰动训练也应作为协议相关的鲁棒性检验，而不应无条件推广为所有扰动条件下的性能保证。

1.8 本章小结

本章从 AUV 长期轨迹预测中的几何、能量、执行器和海流建模需求出发，提出一种结构化神经动力学建模方法，并将其简称为 AUVHamNODE。该方法以 Neural ODE 表达连续时间预测，以 Fossen 型动力学和端口哈密顿思想组织机械存储、耗散、零功率耦合和外部广义力，并以海流条件下的数据态-模型态转换维持总体速度与相对水速度的一致性。

本章给出了该模型的状态表示、速度约定、SE(3) 运动学、相对动量动力学、非保守广义力分解、执行器滞后和外源通道，并证明了静水机械核心在限定条件下的能量平衡性质。训练与验证协议进一步将结构保持参数化、控制块损失、长期递推、结构消融、初值扰动和物理诊断联系起来，用于检验结构约束是否在长期预测中发挥作用。上述内容构成本章后续实验分析和证据边界讨论的理论基础。

参考文献

- Faheem Ahmed, Xianbo Xiang, Chaicheng Jiang, Gong Xiang, and Shaolong Yang. Survey on traditional and AI based estimation techniques for hydrodynamic coefficients of autonomous underwater vehicle. *Ocean Engineering*, 268:113300, 2023. doi: 10.1016/j.oceaneng.2022.113300.
- Wilmer Ariza Ramirez, Juš Kocijan, Zhi Quan Leong, Hung Duc Nguyen, and Shantha Gamini Jayasinghe. Dynamic system identification of underwater vehicles using multi-output gaussian processes. *Machine Intelligence Research*, 18(5):681–693, 2021. doi: 10.1007/s11633-021-1308-x.
- Vladimir I. Arnold. *Mathematical Methods of Classical Mechanics*, volume 60 of *Graduate Texts in Mathematics*. Springer, 2 edition, 1989. doi: 10.1007/978-1-4757-1693-1.
- Francesco Bullo and Andrew D. Lewis. *Geometric Control of Mechanical Systems*. Springer, 2004. doi: 10.1007/978-1-4899-7276-7.
- Massimo Caccia, Giovanni Indiveri, and Gianmarco Veruggio. Modeling and identification of open-frame variable configuration unmanned underwater vehicles. *IEEE Journal of Oceanic Engineering*, 25(2):227–240, 2000. doi: 10.1109/48.838986.
- Ricky T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, and David K. Duvenaud. Neural ordinary differential equations. In *Advances in Neural Information Processing Systems*, volume 31, 2018.
- Kamel Cherifi. An overview on recent machine learning techniques for port Hamiltonian systems. *Physica D: Nonlinear Phenomena*, 411:132620, 2020. doi: 10.1016/j.physd.2020.132620.
- Shaan Desai, Marios Mattheakis, David Sondak, Pavlos Protopapas, and Stephen J. Roberts. Port-Hamiltonian neural networks for learning explicit time-dependent dynamical systems. *Physical Review E*, 104(3):034312, 2021. doi: 10.1103/PhysRevE.104.034312.

- Sølve Eidnes, Alexander J. Stasik, Christian Sterud, Signe Riemer-Sørensen, and Eivind Bøhn. Pseudo-Hamiltonian neural networks with state-dependent external forces. *Physica D: Nonlinear Phenomena*, 446:133673, 2023. doi: 10.1016/j.physd.2023.133673.
- Melek Ertogan and Philip A. Wilson. Modelling using neural networks and dynamic position control for unmanned underwater vehicles. *Journal of Eta Maritime Science*, 12(1):64–73, 2024. doi: 10.4274/jems.2024.46514.
- Xinyu Fei, Lu Wang, Ruiheng Liu, Shipang Qian, Jiaxuan Song, Suohang Zhang, Yanhu Chen, and Canjun Yang. A physics-guided hybrid network for robust hydrodynamic parameter identification of UUVs under lumped disturbances. *Journal of Marine Science and Engineering*, 14(5):434, 2026. doi: 10.3390/jmse14050434.
- Thor I. Fossen. *Handbook of Marine Craft Hydrodynamics and Motion Control*. John Wiley & Sons, 2011. doi: 10.1002/9781119994138.
- Thor I. Fossen. *Handbook of Marine Craft Hydrodynamics and Motion Control*. John Wiley & Sons, 2 edition, 2021. doi: 10.1002/9781119575054.
- Samuel Greydanus, Misko Dzamba, and Jason Yosinski. Hamiltonian neural networks. In *Advances in Neural Information Processing Systems*, volume 32, 2019.
- Ernst Hairer, Christian Lubich, and Gerhard Wanner. *Geometric Numerical Integration: Structure-Preserving Algorithms for Ordinary Differential Equations*. Springer, 2 edition, 2006. doi: 10.1007/3-540-30666-8.
- George Em Karniadakis, Ioannis G. Kevrekidis, Lu Lu, Paris Perdikaris, Sifan Wang, and Liu Yang. Physics-informed machine learning. *Nature Reviews Physics*, 3:422–440, 2021. doi: 10.1038/s42254-021-00314-5.
- Patrick Kidger, James Morrill, James Foster, and Terry Lyons. Neural controlled differential equations for irregular time series. In *Advances in Neural Information Processing Systems*, volume 33, 2020.
- Xan Macatangay, Sargon A. Gabriel, Reza Hoseinnezhad, Anthony Fowler, and Alireza Bab-Hadiashar. Machine learning for modeling underwater vehicle dynamics: Overview and insights. *IEEE Access*, 12:139486–139504, 2024. doi: 10.1109/ACCESS.2024.3464644.

- Jyoti Prakash Panda, Arindam Mitra, and Hari V. Warrior. A review on the hydrodynamic characteristics of autonomous underwater vehicles. *Proceedings of the Institution of Mechanical Engineers, Part M: Journal of Engineering for the Maritime Environment*, 235(1):15–29, 2021. doi: 10.1177/1475090220936896.
- A. B. Phillips, S. R. Turnock, and M. Furlong. The use of computational fluid dynamics to aid cost-effective hydrodynamic design of autonomous underwater vehicles. *Proceedings of the Institution of Mechanical Engineers, Part M: Journal of Engineering for the Maritime Environment*, 224(4):239–254, 2010. doi: 10.1243/14750902JEME199.
- Timothy Prestero. Verification of a six-degree of freedom simulation model for the REMUS autonomous underwater vehicle. M.s. thesis, Massachusetts Institute of Technology and Woods Hole Oceanographic Institution, 2001.
- Christopher Rackauckas, Yingbo Ma, Julius Martensen, Collin Warner, Kirill Zubov, Rohit Supekar, Dominic Skinner, Ali Ramadhan, and Alan Edelman. Universal differential equations for scientific machine learning, 2020.
- Maziar Raissi, Paris Perdikaris, and George E. Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019. doi: 10.1016/j.jcp.2018.10.045.
- Alok Sahoo, Santosh Kumar Dwivedy, and P. S. Robi. Advancements in the field of autonomous underwater vehicle. *Ocean Engineering*, 181:145–160, 2019. doi: 10.1016/j.oceaneng.2019.04.011.
- Shanshan Song, Jun Liu, Jiani Guo, Jun Wang, Yanxin Xie, and Jun-Hong Cui. Neural-network-based AUV navigation for fast-changing environments. *IEEE Internet of Things Journal*, 7(10):9773–9783, 2020. doi: 10.1109/JIOT.2020.2988313.
- Pepijn W. J. van de Ven, Tor A. Johansen, Asgeir J. Sørensen, Colin Flanagan, and Daniel Toal. Neural network augmented identification of underwater vehicle models. *Control Engineering Practice*, 15(6):715–725, 2007. doi: 10.1016/j.conengprac.2005.11.004.
- Arjan van der Schaft. *L_2 -Gain and Passivity Techniques in Nonlinear Control*. Springer, 3 edition, 2017. doi: 10.1007/978-3-319-49992-5.
- Arjan J. van der Schaft and Dimitri Jeltsema. Port-hamiltonian systems theory: An introductory overview. *Foundations and Trends in Systems and Control*, 1(2–3):173–378, 2014. doi: 10.1561/26000000002.

- Russell B. Wynn, Veerle A. I. Huvenne, Tim P. Le Bas, Bramley J. Murton, Douglas P. Connelly, Brian J. Bett, Henry A. Ruhl, Kirsty J. Morris, Jeff Peakall, Daniel R. Parsons, Esther J. Sumner, Stephen E. Darby, Robert M. Dorrell, and James E. Hunt. Autonomous underwater vehicles (AUVs): Their past, present and future contributions to the advancement of marine geoscience. *Marine Geology*, 352:451–468, 2014. doi: 10.1016/j.margeo.2014.03.012.
- Feng Xu, Zao-Jian Zou, Jian-Chuan Yin, and Jian Cao. Identification modeling of underwater vehicles’ nonlinear dynamics based on support vector machines. *Ocean Engineering*, 67:68–76, 2013. doi: 10.1016/j.oceaneng.2013.02.006.
- Jieen Yao, Junzheng Yang, Chenghao Zhang, Jing Zhang, and Tianchi Zhang. Autonomous underwater vehicle trajectory prediction with the nonlinear kepler optimization algorithm–bidirectional long short-term memory–time-variable attention model. *Journal of Marine Science and Engineering*, 12(7):1115, 2024. doi: 10.3390/jmse12071115.
- Yifeng Zhao, Zhiqiang Hu, Weifeng Du, Lingbo Geng, and Yi Yang. Research on modeling method of autonomous underwater vehicle based on a physics-informed neural network. *Journal of Marine Science and Engineering*, 12(5):801, 2024. doi: 10.3390/jmse12050801.
- Yaofeng Desmond Zhong, Biswadip Dey, and Amit Chakraborty. Dissipative SymODEN: Encoding Hamiltonian dynamics with dissipation and control into deep learning, 2020a.
- Yaofeng Desmond Zhong, Biswadip Dey, and Amit Chakraborty. Symplectic ODE-Net: Learning Hamiltonian dynamics with control. In *International Conference on Learning Representations*, 2020b.