

面向 AUV 长期预测的结构化神经动力学建模 方法

摘要

水下航行器运动建模需要同时处理六自由度刚体运动学、强耦合水动力、执行器动态和环境海流影响。传统理论分析、计算流体力学仿真和系统辨识方法能够提供重要物理依据，但在水动力参数获取、复杂工况覆盖、计算代价和长期递推泛化方面仍存在局限。深度学习将运动建模表述为受控多变量时序预测问题，并可进一步通过神经微分方程学习连续时间向量场。为提高长期预测中的几何一致性和功率结构可解释性，本章构造一种面向 AUV 长期预测的结构化神经动力学模型。该模型结合 Fossen 型六自由度动力学的功率结构和 port-Hamiltonian 系统的能量平衡思想，在连续时间向量场中引入 SE(3) 位姿运动学、海流条件下的相对水速度变量、机械存储函数、正定耗散、斜对称零功率耦合、执行器滞后和可学习广义力分支。为便于与实现和实验标识对应，下文将该模型简称为 AUVHamNODE。本章建立数据空间总体速度、模型空间相对水速度与惯性系海流速度之间的转换关系，给出静水机械核心的能量平衡命题，并将长期递推、结构消融、初值扰动和内部物理诊断组织为验证协议。本章讨论的 port-Hamiltonian 性质限定于开放式机械核心及其广义力-速度端口功率平衡；完整航行器-执行器-环境增强系统则作为受控开放系统进行建模和验证。

目录

第一章	面向 AUV 长期预测的结构化神经动力学建模方法	2
1.1	研究问题与方法概述	2
1.2	相关建模基础	3
1.2.1	神经网络时序预测模型	3
1.2.2	神经常微分方程模型	3
1.2.3	Hamiltonian 与 port-Hamiltonian 神经模型	4
1.2.4	AUV 六自由度动力学的功率结构	4
1.3	受控状态表示与海流速度约定	5
1.3.1	坐标系、状态与控制	5
1.3.2	总体速度与相对水速度	5
1.3.3	数据态、模型态与受控初值问题	6
1.4	结构化连续时间动力学模型	7
1.4.1	SE(3) 运动学	8
1.4.2	相对动量与机械存储函数	8
1.4.3	非保守广义力与执行器通道	9
1.4.4	相对动量动力学	9
1.5	能量平衡与理论边界	10
1.6	训练目标与验证协议	11
1.6.1	结构保持参数化	11
1.6.2	控制块训练目标	11
1.6.3	长期递推与证据口径	12
1.6.4	结构消融设置	13
1.7	讨论	13
1.8	本章小结	14

第一章 面向 AUV 长期预测的结构化神经动力学建模方法

1.1 研究问题与方法概述

水下航行器运动建模的传统路线主要包括理论分析、计算流体力学仿真和系统辨识。理论分析以刚体动力学、流体附加质量、阻尼、恢复力和执行器广义力为核心，能够给出清晰的物理结构和可解释的能量关系；计算流体力学能够在给定几何和流场条件下求解或刻画更细致的压力、涡量和升阻力分布；系统辨识则利用试验或仿真数据估计未知参数，使模型更贴近特定平台和工况。这些路线构成水下航行器动力学研究的基础。

上述方法也存在共同限制。理论模型往往依赖水动力导数、执行器模型、流场假设和平台参数，复杂机动或强海流工况下的半经验项难以完全由第一性原理闭合；高保真流体仿真计算代价较高，通常难以直接作为大量长时域轨迹预测的在线模型；系统辨识依赖数据覆盖和激励设计，所得模型的适用范围常受限于辨识工况。对于长期递推预测任务，模型不仅需要拟合局部状态导数，还需要在姿态、速度、能量和控制输入之间保持一致的结构关系。

深度学习提供了另一种表述方式：将水下航行器运动建模转化为受控多变量时序预测问题。该视角弱化了对显式水动力参数的依赖，使模型可以从轨迹数据中学习复杂非线性关系。然而，普通神经时序模型并不自动继承水下航行器动力学的结构。若直接学习离散状态转移，长期递推误差会不断反馈到后续输入中；若姿态被视为普通欧氏向量，预测轨迹可能偏离旋转群结构；若速度、控制和水动力项仅作为非结构化特征输入，模型难以区分惯性运动、相对水运动、耗散和输入功率的不同角色。因此，深度学习路线需要进一步从普通时序预测走向结构化动力学学习。

基于上述问题，本章提出一种面向 AUV 长期预测的结构化神经动力学建模方法。该方法的核心不是把工程化 AUV 模拟器完整改写成严格闭合的 port-Hamiltonian 系统，而是将六自由度 AUV 动力学中相对可靠的几何、能量、耗散、执行器和海流速度约定转化为可学习、可消融、可长期递推验证的连续时间结构化假设空间。为便于与实现和实验标识对应，下文将该模型简称为 AUVHamNODE。

本章围绕五个问题展开。第一，说明神经网络时序建模、Neural ODE、Hamiltonian

Neural Network、port-Hamiltonian Neural Network 和 AUV 六自由度动力学之间的关系；第二，建立受控轨迹预测的状态表示和海流条件下的速度口径；第三，构造嵌入 SE(3) 运动学、机械存储函数和非保守广义力分解的连续时间模型；第四，给出静水机械核心的能量平衡性质和理论声称边界；第五，说明训练目标、长期递推验证、结构消融和证据状态筛选方式。

1.2 相关建模基础

1.2.1 神经网络时序预测模型

设 s_k 表示离散采样时刻的状态， u_k 表示控制输入， c_k 表示环境或任务上下文，则数据驱动预测可以写为

$$\hat{s}_{k+1:k+H} = \mathcal{F}_\theta(s_{0:k}, u_{0:k+H-1}, c_{0:k+H-1}), \quad (1.1)$$

其中 H 为预测步长， $\mathcal{F}_\theta$ 可由多层感知机、循环网络、卷积时序网络或注意力模型等神经网络参数化。若只关注短时预测，这类模型能够直接从数据中学习复杂输入-输出关系；但在长时域递推中，模型误差会通过状态反馈逐步累积，且普通离散映射通常缺少姿态几何、能量耗散和输入功率等结构约束。

另一类常见表述是学习单步状态转移：

$$\hat{s}_{k+1} = F_\theta(s_k, u_k, c_k). \quad (1.2)$$

这种形式训练和实现都较方便，但模型与采样间隔紧密绑定。当控制块长度、采样间隔或评估时域发生变化时，单步离散映射未必给出稳定的连续时间解释。因此，本章将普通神经时序预测作为问题起点，而不是最终模型形式。

1.2.2 神经常微分方程模型

当预测任务关注长时域递推、变步长积分或不同控制块长度时，更自然的表述是学习连续时间向量场：

$$\dot{y} = f_\theta(y, u, c), \quad \hat{y}(t) = y(t_0) + \int_{t_0}^t f_\theta(y(\tau), u(\tau), c(\tau)) d\tau. \quad (1.3)$$

Neural ODE 将该向量场参数化为神经网络，并通过数值积分定义从初值到预测轨迹的映射 (Chen et al., 2018)。相较于固定步长离散映射，Neural ODE 更接近动力学系统的表达形式，也便于把运动学、能量和输入端口等连续时间结构写入模型。

普通 Neural ODE 仍然只是连续时间黑箱向量场。若 f_θ 不受任何结构约束，模型可以拟合局部导数，却不一定保持姿态几何、能量功率关系、耗散非负性或执行器滞后等物理特征。因此，连续时间化只是第一步；水下航行器运动预测还需要在向量场中嵌入合适的结构约束。

1.2.3 Hamiltonian 与 port-Hamiltonian 神经模型

Hamiltonian Neural Network 将神经网络与能量函数联系起来, 通过学习标量 Hamiltonian H_θ 构造保守系统向量场 (Greydanus et al., 2019)。在正则坐标 (canonical coordinates) z 下, 典型形式可写为

$$\dot{z} = J\nabla H_\theta(z), \quad J = -J^\top, \quad (1.4)$$

其中斜对称矩阵 J 保证 $\dot{H}_\theta = \nabla H_\theta^\top J \nabla H_\theta = 0$ 。该思想适合表达保守动力学中的能量守恒, 但水下航行器是受控、耗散并受环境扰动影响的开放系统, 仅有 HNN 的保守结构并不足以描述实际运动。

port-Hamiltonian 系统在 Hamiltonian 能量存储的基础上引入耗散和输入端口 (van der Schaft and Jeltsema, 2014; van der Schaft, 2017)。其抽象形式可写为

$$\dot{z} = (J_\theta(z) - R_\theta(z))\nabla H_\theta(z) + G_\theta(z)u, \quad J_\theta = -J_\theta^\top, \quad R_\theta \succeq 0. \quad (1.5)$$

此时

$$\dot{H}_\theta = -\nabla H_\theta^\top R_\theta \nabla H_\theta + \nabla H_\theta^\top G_\theta u, \quad (1.6)$$

从而能区分储能、耗散和外部输入功率。对水下航行器而言, port-Hamiltonian 思想提供了将能量存储、耗散、零功率耦合和外部广义力分开建模的原则。

1.2.4 AUV 六自由度动力学的功率结构

水下航行器六自由度动力学常用 Fossen 型方程表示 (Fossen, 2011, 2021):

$$\dot{\eta} = J_\eta(\eta)\nu, \quad M\dot{\nu} + C(\nu)\nu + D(\nu)\nu + g(\eta) = \tau. \quad (1.7)$$

其中 η 表示位置和姿态坐标, ν 表示体坐标系速度, $M \succ 0$ 为刚体质量和附加质量矩阵, $C(\nu)$ 为 Coriolis/向心项, $D(\nu)$ 为阻尼, $g(\eta)$ 为重力和浮力恢复项, τ 为控制或外部广义力。

在理想条件下, 该方程具有明确的功率解释。若 $C(\nu)$ 满足零功率性质 $\nu^\top C(\nu)\nu = 0$, 阻尼满足 $D(\nu) \succeq 0$, 恢复力来自势能 $V(\eta)$, 并且运动学与势能梯度配对一致, 则可定义机械能

$$H(\eta, \nu) = \frac{1}{2}\nu^\top M\nu + V(\eta). \quad (1.8)$$

对 H 求导并代入式 (1.7), 可得到

$$\dot{H} = \nu^\top \tau - \nu^\top D(\nu)\nu. \quad (1.9)$$

该式说明, 在上述标准假设下, Fossen 形式具有与 port-Hamiltonian 理论相容的功率结构: 质量矩阵定义动能, 恢复力对应势能, Coriolis/向心项不做功, 阻尼耗散机械能, 控制输入通过广义力端口交换功率。

若引入动量 $p = M\nu$ ，则式 (1.7) 可被理解为一种机械系统的 port-Hamiltonian 风格表达。Hamiltonian 可写为

$$H(\eta, p) = \frac{1}{2}p^\top M^{-1}p + V(\eta), \quad (1.10)$$

其中 $\partial H/\partial p = M^{-1}p = \nu$ 。在满足零功率、正耗散和势能配对条件时，非保守项可以分解为耗散项与输入端口项，系统能量导数仍满足式 (1.9)。

实际水下航行器工程模型通常不是纯粹由闭合 Hamiltonian 结构生成。为了覆盖真实平台和复杂工况，模型往往包含半经验阻尼、舵面升力、桨推力、横流阻力、执行器一阶滞后、限幅、控制器闭环以及海流外源等成分。这些成分可以分别解释为耗散、经验广义力、外部输入或外源扰动，但通常不能在不附加额外假设的情况下统一写成标准闭合 port-Hamiltonian 系统。因此，本章采用 Fossen 结构揭示的功率角色作为建模依据，并将这些角色转化为神经向量场中的结构约束。

1.3 受控状态表示与海流速度约定

1.3.1 坐标系、状态与控制

设 n 表示惯性坐标系或导航坐标系， b 表示航行器体坐标系。航行器配置变量定义为

$$q = (x, R), \quad x \in \mathbb{R}^3, \quad R \in \text{SO}(3), \quad (1.11)$$

其中 x 表示惯性系位置或控制块内以初始位置为原点的相对位置， R 将体坐标系向量映射到惯性坐标系。体坐标系角速度记为 $\omega \in \mathbb{R}^3$ 。执行器命令记为 $u_c \in \mathbb{R}^m$ ，实际执行器状态记为 $u_a \in \mathbb{R}^m$ 。二者具有不同物理含义： u_c 是控制器或数据集给出的命令， u_a 是经过执行器动态后的内部状态，并作为广义力分支的输入之一。

一个训练或验证控制块由采样时刻 $\{t_i\}_{i=0}^T$ 上的状态序列组成。数据空间保存可观测或可重建的轨迹状态，本文记为

$$s_i = [x_i, \text{vec}(R_i), \nu_{b,i}, u_{a,i}, u_{c,i}, v_{c,i}^n, z_{\text{ref}}] \quad (1.12)$$

表示。这里 $v_c^n \in \mathbb{R}^3$ 为惯性系海流速度， $z_{\text{ref}} \in \mathbb{R}$ 为可选深度上下文；无海流数据可令 $v_c^n = 0$ ，无绝对深度上下文的数据可省略 z_{ref} 。向量化符号 $\text{vec}(R)$ 仅表示存储格式；数学上姿态变量仍受 $R \in \text{SO}(3)$ 约束。数据态 s_i 的速度槽采用总体速度口径，其物理含义由下一小节给出。

1.3.2 总体速度与相对水速度

有海流时，航行器相对于惯性系的总体速度与相对于周围水体的速度不同。总体速度描述航行器位姿在惯性系中的变化；相对水速度描述航行器相对于局部水体的运

动, 直接影响阻尼、升力和横向水动力等非保守广义力。令惯性系海流速度为 $v_c^n \in \mathbb{R}^3$, 则体坐标系海流速度为

$$v_c^b = R^\top v_c^n. \quad (1.13)$$

数据空间中的体坐标系总体速度记为

$$\nu_b = \begin{bmatrix} v_b \\ \omega \end{bmatrix}, \quad (1.14)$$

其中 $v_b \in \mathbb{R}^3$ 是航行器相对于惯性系运动的体坐标系线速度, $\omega \in \mathbb{R}^3$ 是体坐标系角速度。模型内部用于水动力相关广义力计算的相对水速度记为

$$\nu_r = \begin{bmatrix} v_r \\ \omega \end{bmatrix}, \quad v_r = v_b - v_c^b. \quad (1.15)$$

海流只平移线速度分量, 不改变体坐标系角速度。因此, 数据空间和模型空间之间的速度契约为

$$\nu_r = \nu_b - \begin{bmatrix} R^\top v_c^n \\ 0 \end{bmatrix}, \quad \nu_b = \nu_r + \begin{bmatrix} R^\top v_c^n \\ 0 \end{bmatrix}. \quad (1.16)$$

无海流时可取 $v_c^n = 0$, 式 (1.16) 退化为 $\nu_r = \nu_b$ 。上述变量关系保证位置运动学和水动力建模使用各自适合的速度口径: 位置 x 相对于惯性系变化, 因此由总体速度推进; 阻尼、升力、横向耦合和执行器相关水动力主要依赖航行器相对于水体的运动, 因此由相对水速度参数化。对应的位置运动学可写为

$$\dot{x} = Rv_b = R(v_r + R^\top v_c^n) = Rv_r + v_c^n. \quad (1.17)$$

式 (1.17) 只说明线速度口径的转换; 完整的姿态运动学和相对动量动力学在下一节的模型构造中给出。




图 1.1: 海流条件下数据态、模型态与输出态之间的速度变量关系。数据空间保留总体速度, ODE 模型空间使用相对水速度, 输出评估前再恢复总体速度。

1.3.3 数据态、模型态与受控初值问题

训练数据保存总体速度口径下的状态

$$s = [x, R, \nu_b, u_a, u_c, v_c^n, z_{\text{ref}}], \quad s \in \mathcal{S}_d, \quad (1.18)$$

ODE 求解器内部使用相对水速度口径下的增强状态

$$y = [x, R, \nu_r, u_a, u_c, v_c^n, z_{\text{ref}}], \quad y \in \mathcal{S}_m. \quad (1.19)$$

其中 $\mathcal{S}_d$ 和 $\mathcal{S}_m$ 分别表示数据态空间和模型态空间；二者在位置、姿态、执行器状态、命令和外源上下文上共享同一数值，只在线速度口径上不同。为简化记号，定义

$$\Delta_c(R, v_c^n) = \begin{bmatrix} R^\top v_c^n \\ 0 \end{bmatrix}. \quad (1.20)$$

则数据态到模型态的映射为

$$\mathcal{T}_{d \rightarrow m}(s) = [x, R, \nu_b - \Delta_c(R, v_c^n), u_a, u_c, v_c^n, z_{\text{ref}}], \quad (1.21)$$

模型态到数据态的映射为

$$\mathcal{T}_{m \rightarrow d}(y) = [x, R, \nu_r + \Delta_c(R, v_c^n), u_a, u_c, v_c^n, z_{\text{ref}}]. \quad (1.22)$$

图 1.1 概括了这两个映射及其物理使用口径。

由此，受控轨迹预测任务可表述为一个带状态转换的连续时间初值问题。给定初始数据态 s_0 、控制块内的命令 u_c 和外源上下文 $c = (v_c^n, z_{\text{ref}})$ ，先将初值转换为模型态

$$y_0 = \mathcal{T}_{d \rightarrow m}(s_0). \quad (1.23)$$

神经常微分方程在模型态空间中产生连续时间流

$$\hat{y}(t_i) = \Phi_\theta(t_i; t_0, y_0, u_c, c), \quad i = 0, \dots, T, \quad (1.24)$$

再通过输出映射回到数据空间

$$\hat{s}_i = \mathcal{T}_{m \rightarrow d}(\hat{y}(t_i)). \quad (1.25)$$

训练损失和评估指标在观测时刻比较 $\hat{s}_i$ 与真实数据态 s_i 。因此，位置、姿态、总体速度和执行器状态等可观测量始终在数据空间解释；相对水速度则作为模型空间变量，用于水动力建模和内部诊断。该约定使后续 SE(3) 运动学、机械能模型、训练损失和长期 rollout 指标使用一致的状态口径。

1.4 结构化连续时间动力学模型

前文给出了本章方法的两个来源。受控时序预测表述提供了从轨迹数据中学习复杂非线性动力学的形式基础，但普通离散模型和非结构化 Neural ODE 缺少几何与能量结构；Fossen 型动力学和 port-Hamiltonian 表述提供了质量、Coriolis、阻尼、恢复力和输入功率之间的角色划分，但实际工程模型通常包含半经验项、执行器动态和环境外源。AUVHamNODE 的目标是在连续时间可学习向量场中保留这些关键结构，并将无法解析闭合的非保守效应交由受约束的神经参数化表达。

AUVHamNODE 在连续时间神经向量场中嵌入以下约束：

1. 位姿演化遵循 SE(3) 刚体运动学；
2. 机械能由正定质量矩阵和标量势能函数定义；
3. 非保守广义力分解为正定耗散、斜对称零功率耦合和可学习外部广义力；
4. 控制命令通过执行器状态进入广义力分支；
5. 环境外源作为状态上下文参与速度转换和广义力计算。

这些约束使模型处于传统物理模型和非结构化深度模型之间：它不要求所有水动力项可解析辨识，也不放弃机械系统的基本结构。

1.4.1 SE(3) 运动学

AUVHamNODE 显式编码刚体位姿运动学：

$$\dot{x} = Rv_b, \quad \dot{R} = R\hat{\omega}. \quad (1.26)$$

其中 $\hat{\omega} \in \mathfrak{so}(3)$ 表示角速度 ω 对应的反对称矩阵。式 (1.26) 将姿态导数限制在旋转群的切空间方向上。当存在海流外源时， $v_b = v_r + R^\top v_c^n$ ，因此

$$\dot{x} = R(v_r + R^\top v_c^n) = Rv_r + v_c^n. \quad (1.27)$$

连续时间层面，若 $R(0) \in \text{SO}(3)$ ，则 $\dot{R} = R\hat{\omega}$ 与 $\text{SO}(3)$ 的切空间相容。若实际数值实现采用普通 ODE 求解器对旋转矩阵元素积分，则离散数值解仍可能出现正交性漂移，因此评估中需要同时报告姿态误差与 $\text{SO}(3)$ 正交性诊断。

1.4.2 相对动量与机械存储函数

模型使用相对水速度定义相对动量

$$p_r = M_\theta v_r, \quad (1.28)$$

其中 $M_\theta \in \mathbb{R}^{6 \times 6}$ 为正定质量矩阵。机械存储函数定义为

$$H_\theta(q, p_r) = \frac{1}{2} p_r^\top M_\theta^{-1} p_r + V_\theta(q), \quad (1.29)$$

其中 $V_\theta(q)$ 为标量势能函数。该写法继承 Fossen/pH 结构中的能量账本，使保守广义力与同一个标量存储函数相关。

1.4.3 非保守广义力与执行器通道

水动力阻尼、升力、执行器作用和未建模效应通过非保守广义力进入相对动量动力学。模型将该部分写为

$$f_{\theta}^{\text{nc}} = -D_{\theta}(\xi)\nu_r + J_{\theta}(\xi)\nu_r + \tau_{\theta}(\nu_r, u_a, c), \quad (1.30)$$

其中 $D_{\theta}(\xi) \succeq 0$ 表示耗散矩阵, $J_{\theta}(\xi) = -J_{\theta}(\xi)^{\top}$ 表示斜对称零功率耦合矩阵, τ_{θ} 表示由执行器状态和上下文驱动的可学习广义力分支。条件变量 ξ 表示耗散和零功率耦合分支可使用的运动特征; 在基本情形下 $\xi = \nu_r$, 在海流扩展中可加入体坐标海流速度 v_c^b 或总体线速度 v_b 。该分解是物理诱导的功能分解, 不保证唯一恢复真实水动力项。

执行器命令 u_c 不直接等同于实际广义力。实际执行器状态满足

$$\dot{u}_a = T_{\theta}^{-1}(u_c - u_a), \quad \dot{u}_c = 0, \quad (1.31)$$

其中 $T_{\theta} \in \mathbb{R}_{>0}^m$ 为正时间常数。环境外源在单个积分窗口内作为上下文携带, 例如

$$\dot{v}_c^n = 0. \quad (1.32)$$

该通道用于状态转换和可选广义力条件特征。本章模型将环境场作为外源上下文处理, 而非闭合 Hamiltonian 环境子系统。

1.4.4 相对动量动力学

综合运动学、势能梯度和非保守广义力, 模型在相对动量变量上构造连续时间向量场:

$$\dot{p}_r = \text{ad}_{\nu_r}^* p_r + f_{\theta}^V(q) + f_{\theta}^{\text{nc}}, \quad (1.33)$$

令 $p_r = [p_v^{\top}, p_{\omega}^{\top}]^{\top}$, $\nu_r = [v_r^{\top}, \omega^{\top}]^{\top}$ 。本章采用的体坐标动量耦合项可写为

$$\text{ad}_{\nu_r}^* p_r = \begin{bmatrix} p_v \times \omega \\ p_{\omega} \times \omega + p_v \times v_r \end{bmatrix}. \quad (1.34)$$

该式给出本章使用的 ad^* 符号约定, 并满足

$$\nu_r^{\top} \text{ad}_{\nu_r}^* p_r = v_r^{\top} (p_v \times \omega) + \omega^{\top} (p_{\omega} \times \omega + p_v \times v_r) = 0, \quad (1.35)$$

因而该项只改变体坐标动量分量之间的耦合, 不改变机械存储能量。势能诱导的保守广义力 $f_{\theta}^V(q)$ 由 V_{θ} 的自动微分梯度构造。若将 $R_{i:}$ 记为 R 的第 i 行, $\partial V_{\theta}/\partial R_{i:}$ 记为对应行梯度, 则可写为

$$f_{\theta}^V(q) = \begin{bmatrix} -R^{\top} \nabla_x V_{\theta}(q) \\ \sum_{i=1}^3 R_{i:} \times \frac{\partial V_{\theta}(q)}{\partial R_{i:}} \end{bmatrix}. \quad (1.36)$$

在静水条件下, $\dot{x} = Rv_r$ 、 $\dot{R} = R\hat{\omega}$, 式 (1.36) 满足

$$\nu_r^\top f_\theta^V(q) = -\frac{d}{dt}V_\theta(q). \quad (1.37)$$

该配对关系是后文能量平衡命题成立的关键条件。质量矩阵为常矩阵时, 相对速度导数由

$$\dot{\nu}_r = M_\theta^{-1}\dot{p}_r \quad (1.38)$$

给出。

1.5 能量平衡与理论边界

定义 1.1 (AUVHamNODE 的机械核心). 在给定外部广义力 $\tau_\theta(\nu_r, u_a, c)$ 的条件下, AUVHamNODE 的机械核心指由配置 $q = (x, R)$ 、相对动量 p_r 、机械存储函数 $H_\theta(q, p_r)$ 、SE(3) 运动学、保守广义力 $f_\theta^V(q)$ 、正定耗散项 $-D_\theta(\xi)\nu_r$ 和斜对称零功率耦合项 $J_\theta(\xi)\nu_r$ 组成的连续时间力学子系统。执行器状态 u_a 、命令 u_c 、海流 v_c^n 和深度上下文 z_{ref} 属于增强状态或外源上下文; 它们可以影响广义力分支或速度转换, 但不作为机械存储函数的独立储能变量。因而, 本章的 *port-Hamiltonian* 性质只针对该机械核心的功率平衡, 而不针对完整增强状态作闭合系统声明。

命题 1.1 (静水机械核心的能量平衡). 考虑无海流或静水条件 $v_c^n = 0$ 。假设连续时间精确流满足 $R(t) \in \text{SO}(3)$ 、 $M_\theta \succ 0$ 且 M_θ 不随状态变化、 $D_\theta(\xi) \succeq 0$ 、 $J_\theta(\xi) = -J_\theta(\xi)^\top$, 体坐标动量耦合项满足式 (1.34) 的零功率配对, 且保守广义力满足式 (1.37)。对于机械存储函数 (1.29) 和非保守力分解 (1.30), 机械核心满足

$$\dot{H}_\theta = -\nu_r^\top D_\theta(\xi)\nu_r + \nu_r^\top \tau_\theta(\nu_r, u_a, c). \quad (1.39)$$

特别地, 当 $\tau_\theta = 0$ 时, 机械核心的存储能量非增。

证明. 机械存储函数可分解为动能 $K_\theta = \frac{1}{2}p_r^\top M_\theta^{-1}p_r$ 和势能 $V_\theta(q)$ 。由于 M_θ 为常正定矩阵, 且 $\partial H_\theta / \partial p_r = M_\theta^{-1}p_r = \nu_r$, 动能导数为

$$\dot{K}_\theta = \nu_r^\top \dot{p}_r. \quad (1.40)$$

将式 (1.33) 代入, 得到

$$\dot{K}_\theta = \nu_r^\top \text{ad}_{\nu_r}^* p_r + \nu_r^\top f_\theta^V(q) + \nu_r^\top f_\theta^{\text{nc}}. \quad (1.41)$$

由式 (1.34) 的零功率性质, 第一项为零; 由势能功率配对式 (1.37), 第二项等于 $-\dot{V}_\theta$ 。因此

$$\dot{H}_\theta = \dot{K}_\theta + \dot{V}_\theta = \nu_r^\top f_\theta^{\text{nc}}. \quad (1.42)$$

再代入式 (1.30), 有

$$\nu_r^\top \dot{f}_\theta^{\text{nc}} = -\nu_r^\top D_\theta(\xi) \nu_r + \nu_r^\top J_\theta(\xi) \nu_r + \nu_r^\top \tau_\theta(\nu_r, u_a, c). \quad (1.43)$$

由于 $J_\theta(\xi) = -J_\theta(\xi)^\top$, $\nu_r^\top J_\theta(\xi) \nu_r = 0$, 从而得到式 (1.39)。又因 $D_\theta(\xi) \succeq 0$, 当 $\tau_\theta = 0$ 时有 $\dot{H}_\theta \leq 0$ 。□

该命题刻画的是机械核心在限定条件下的连续时间功率平衡, 并不表示普通数值积分过程严格保持该等式。完整增强模型还包含执行器滞后和环境外源, 且 τ_θ 是由执行器状态与上下文条件化的广义力端口, 因而本章将完整系统作为受控开放系统处理。有外源流场时, 若势能依赖绝对位置或深度, 能量导数还可能包含由外源平移引入的附加功率项。

1.6 训练目标与验证协议

1.6.1 结构保持参数化

神经参数化服务于上述理论对象, 并将部分结构性质直接写入可训练函数类。逆质量矩阵采用 Cholesky 型参数化: 令 L_M 为下三角矩阵, 其对角元由 softplus 映射保证为正, 则

$$M_\theta^{-1} = L_M L_M^\top \succ 0, \quad M_\theta = (M_\theta^{-1})^{-1}. \quad (1.44)$$

势能分支输出标量 $V_\theta(q)$, 实际实现中可使用重力方向、姿态特征和可选绝对深度上下文作为输入。耗散分支在完整形式下输出下三角因子 $L_D(\xi)$, 并构造

$$D_\theta(\xi) = L_D(\xi) L_D(\xi)^\top \succeq 0; \quad (1.45)$$

对角阻尼消融则使用正对角元素构造 $\text{diag}(d_\theta(\xi))$ 。斜对称分支输出矩阵上三角参数并反对称化:

$$J_\theta(\xi) = A_\theta(\xi) - A_\theta(\xi)^\top. \quad (1.46)$$

可学习广义力分支 τ_θ 接收执行器状态、相对速度和可选海流特征, 用于表达执行器驱动和其他无法解析闭合的非保守广义力。

上述参数化将正定性、半正定性和斜对称性直接作用于可训练函数类。由参数化直接保证的性质构成模型结构约束; 由数值积分、状态转换和数据分布共同决定的性质, 则通过训练目标和评估指标进行检验。

1.6.2 控制块训练目标

训练数据由控制块序列组成。在单个控制块内, 控制命令和外源上下文保持分段常值, 模型从块初值出发积分生成预测轨迹。预测过程为

$$y_0 = \mathcal{T}_{d \rightarrow m}(s_0), \quad \hat{y}(t_i) = \Phi_\theta(t_i; t_0, y_0, u_c, c), \quad \hat{s}_i = \mathcal{T}_{m \rightarrow d}(\hat{y}(t_i)), \quad (1.47)$$

表 1.1: 理论对象与可训练参数化的对应关系

理论对象	参数化目标	结构作用
M_θ^{-1}	$L_M L_M^\top$ 正定逆质量矩阵	保证动能二次型正定，定义相对动量和速度映射。
$V_\theta(q)$	标量势能网络与线性先验	使保守广义力来自同一能量函数。
$D_\theta(\xi)$	满矩阵正定阻尼或对角正阻尼	保证耗散项不向机械核心注入能量。
$J_\theta(\xi)$	反对称化耦合矩阵	表达零功率横向或升力类耦合。
$\tau_\theta(\nu_r, u_a, c)$	执行器状态和上下文驱动的广义力网络	表达执行器驱动和未建模非保守效应；不等同于标准 $G(q)u$ 端口矩阵。
T_θ	softplus 正时间常数	表达命令到实际执行器状态的一阶滞后。
$\mathcal{T}_{d \rightarrow m}, \mathcal{T}_{m \rightarrow d}$	数据/模型状态转换	维持输出空间和内部动力学变量的一致性。

其中 Φ_θ 表示由神经常微分方程积分得到的流映射。训练时，目标轨迹也转换到模型态 $y_i = \mathcal{T}_{d \rightarrow m}(s_i)$ ，使有海流样本的速度损失作用于相对水速度口径；位置、姿态和执行器状态在数据态与模型态中保持同一数值。一个典型加权训练目标可写为

$$\mathcal{L} = \sum_i \lambda_x \|\hat{x}_i - x_i\|^2 + \lambda_R d_{\text{SO}(3)}(\hat{R}_i, R_i)^2 + \lambda_\nu \|\hat{\nu}_{r,i} - \nu_{r,i}\|^2 + \lambda_a \|\hat{u}_{a,i} - u_{a,i}\|^2 + \lambda_{\text{SO}} \mathcal{L}_{\text{SO}(3)}, \quad (1.48)$$

其中 $d_{\text{SO}(3)}$ 为旋转测地距离， $\mathcal{L}_{\text{SO}(3)}$ 为旋转矩阵正交性和行列式正则项。评估和报告时，预测轨迹再通过 $\mathcal{T}_{m \rightarrow d}$ 回到数据态，因此终端位置、姿态和总体速度等可观测指标仍在数据空间解释。

1.6.3 长期递推与证据口径

评估协议的目标不是只比较局部拟合误差，而是检验结构约束是否改善长期递推稳定性、初值扰动鲁棒性和内部物理一致性。数据来源采用受控仿真生成的 AUV 轨迹块，可区分无海流和有海流设置；有海流数据使用式 (1.16) 明确总体速度与相对水速度的转换关系。训练设置至少区分干净初值训练 (clean training) 与基于噪声配置的初值扰动训练 (profile-based noisy initial-condition training)，后者通过预热、斜坡增长和干净样本混合比例控制训练噪声强度。

长期递推预测将上一控制块的预测末状态作为下一控制块初值，用于检验误差累积、姿态漂移、速度发散和数值失败。该任务的首要指标是完成率 (completion rate)、到达目标时域完成率 (completed-to-horizon rate) 和失败原因 (failure reason)，因为

只有模型完成目标时域后，终端误差才具有可比性。失败原因应区分预测发散、ODE 求解失败、NaN/Inf、速度或深度约束违反，以及地面真值递推任务自身失败等情形。

在完成目标时域的样本上，主要误差指标包括终端位置误差、深度误差、旋转测地误差、总体线速度误差、总体角速度误差和误差增长曲线；可进一步报告中位数、第 90 百分位或第 95 百分位轨迹误差以展示长期误差累积。相对速度误差属于模型空间诊断，用于解释水动力建模变量是否一致，不替代数据空间总体速度指标。能量、SO(3) 行列式误差和正交性误差用于解释内部结构是否按预期工作，也不替代外部任务误差。

可复现实验报告需要同时给出数据生成配置、训练/验证/测试划分、随机种子、控制块长度、采样间隔、积分器类型、误差容差、长期递推时域、失败判据、噪声配置和代码环境记录。结果进入主结论前应满足一致的数据协议、评估口径和代码环境记录。目录化结果可优先使用规范化长期递推结果视图生成表格和图，但规范化视图不自动等于当前论文证据；引用具体数值时还需检查证据状态。标记为证据过期、需要复核或仅具有协议敏感性分析含义的结果，只能用于讨论证据边界、协议敏感性或后续工作，不能作为主性能排序的无条件依据。

1.6.4 结构消融设置

模型比较链条覆盖非结构化 full-state 模型、SE(3) 加速度模型、SE(3) 动量模型、port-Hamiltonian 风格结构模型和 AUVHamNODE 完整模型。该链条用于分离几何运动学、动量坐标、能量结构和非保守力分解各自的作用。结构消融对象包括质量先验、耦合阻尼、斜对称零功率耦合、广义力分支条件化方式以及非保守力合并方式。

1.7 讨论

本章方法的 port-Hamiltonian 性质限于开放式机械核心及其功率平衡，不等同于完整航行器-执行器-环境系统的严格闭合 port-Hamiltonian 化。执行器状态、命令输入、海流和深度上下文属于增强状态或外源上下文，它们可以条件化广义力分支或参与速度转换，但不作为机械存储函数中的独立储能变量。因此，本章的理论声明应理解为对结构化连续时间向量场和机械核心功率账本的约束，而不是对完整增强系统的闭合能量守恒声明。

连续时间向量场与 SO(3) 切空间相容，但若数值实现采用普通 ODE 求解器，仍可能产生离散积分层面的正交性误差。因而，姿态预测不能只报告欧氏矩阵误差，还需要报告旋转测地误差、行列式偏差和正交性诊断。若后续采用严格李群积分器或投影积分方案，可进一步区分模型结构误差和数值积分误差。

非保守力分解提供结构诱导的功能角色，不保证唯一辨识真实水动力项。正定耗散、斜对称零功率耦合和可学习广义力分支可以提高假设空间的可解释性，但不同分支之间仍可能存在统计补偿。结构消融和内部物理诊断只能说明这些结构在给定数据

表 1.2: 模型比较与结构消融的证据角色

模型类别	代表模型	证据作用
非结构化状态模型	Full-State Black-Box	检验缺少几何与能量结构时的长期递推风险。
几何基线	SE(3) Acceleration Black-Box	隔离显式位姿运动学对姿态和位置预测的作用。
动量基线	SE(3) Momentum Black-Box	隔离动量坐标和质量矩阵对速度预测的作用。
结构化 pH 基线	pH NODE Merged Force, pH NODE q-Force	检验能量核心和不同广义力组织方式的贡献。
完整模型	AUVHamNODE / pH NODE Full	同时包含速度契约、SE(3) 运动学、机械存储、 $D/J/\tau$ 分解和执行器滞后。
消融模型	No Mass Prior, Diagonal Damping, No Lift, B(u) Only	分别检验质量先验、耦合阻尼、零功率耦合和执行器条件化的必要性。

协议和模型族下的作用，不能单独证明各神经分支逐项恢复了真实物理机理。

当前实验验证对象是受控仿真生成的数据分布。仿真数据能够提供可重复、可消融和可诊断的证据环境，但不等同于真实海试条件下的泛化验证。真实海域中的传感器偏差、海况变化、平台参数误差、执行器非理想性和未建模环境扰动仍需要后续实验支持。基于噪声配置的初值扰动训练也应作为协议相关的鲁棒性检验，而不应无条件推广为所有扰动条件下的性能保证。

1.8 本章小结

本章从 AUV 长期轨迹预测中的几何、能量、执行器和海流建模需求出发，提出一种结构化神经动力学建模方法，并将其简称为 AUVHamNODE。该方法以 Neural ODE 表达连续时间预测，以 Fossen 型动力学和 port-Hamiltonian 思想组织机械存储、耗散、零功率耦合和外部广义力，并以海流条件下的数据态-模型态转换维持总体速度与相对水速度的一致性。

本章给出了该模型的状态表示、速度约定、SE(3) 运动学、相对动量动力学、非保守广义力分解、执行器滞后和外源通道，并证明了静水机械核心在限定条件下的能量平衡性质。训练与验证协议进一步将结构保持参数化、控制块损失、长期递推、结构消融、初值扰动和物理诊断联系起来，用于检验结构约束是否在长期预测中发挥作用。上述内容构成本章后续实验分析和证据边界讨论的理论基础。

参考文献

- Ricky T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, and David K. Duvenaud. Neural ordinary differential equations. In *Advances in Neural Information Processing Systems*, volume 31, 2018.
- Thor I. Fossen. *Handbook of Marine Craft Hydrodynamics and Motion Control*. John Wiley & Sons, 2011. doi: 10.1002/9781119994138.
- Thor I. Fossen. *Handbook of Marine Craft Hydrodynamics and Motion Control*. John Wiley & Sons, 2 edition, 2021. doi: 10.1002/9781119575054.
- Samuel Greydanus, Misko Dzamba, and Jason Yosinski. Hamiltonian neural networks. In *Advances in Neural Information Processing Systems*, volume 32, 2019.
- Arjan van der Schaft. *L_2 -Gain and Passivity Techniques in Nonlinear Control*. Springer, 3 edition, 2017. doi: 10.1007/978-3-319-49992-5.
- Arjan J. van der Schaft and Dimitri Jeltsema. Port-hamiltonian systems theory: An introductory overview. *Foundations and Trends in Systems and Control*, 1(2–3):173–378, 2014. doi: 10.1561/26000000002.