

面向长期状态预测的 AUV 结构化神经动力学 建模方法

摘要

水下航行器运动建模需要同时处理六自由度刚体运动、强耦合水动力、控制输入和环境扰动。传统参数化动力学模型能够提供清晰的物理解释，但其精度和适用范围依赖水动力参数、工况覆盖和模型校准；完全数据驱动模型具有较强表达能力，却通常缺少对长期递推行为有约束作用的运动结构。为服务于位置、姿态和速度等运动状态的长期预测，本章构造一种 AUV 结构化神经动力学模型。该模型以神经常微分方程为基本形式，将 AUV 运动中的几何约束、能量与耗散结构以及可学习非保守效应组织为受控连续时间动力学假设空间，并简称为 AUVHamNODE。本章通过状态表示和海流条件下的速度变量约定定义受控初值问题，在限定条件下分析静水六自由度机械子系统的能量平衡，并以长期递推、结构消融、初值扰动和内部物理诊断检验结构约束的作用。本章讨论的端口哈密顿（port-Hamiltonian）性质限定于开放式机械子系统及其广义力-速度端口功率平衡；完整航行器-执行器-环境增强系统则作为受控开放系统进行建模和验证。

目录

第一章	面向长期状态预测的 AUV 结构化神经动力学建模方法	3
1.1	研究问题与方法概述	3
1.2	相关建模基础	5
1.2.1	AUV 六自由度运动与能量-功率关系	5
1.2.2	水动力参数获取与模型校准边界	6
1.2.3	受控时序预测与连续时间动力学学习	7
1.2.4	科学机器学习与结构化动力学先验	9
1.2.5	哈密顿与端口哈密顿结构化建模基础	9
1.2.6	相关基础小结与本文建模需求	11
1.3	受控状态表示与海流速度约定	12
1.3.1	坐标系、状态与控制	12
1.3.2	总体速度与相对水速度	13
1.3.3	数据态、模型态与受控初值问题	14
1.4	从 Fossen 能量结构到结构保持学习模型	15
1.4.1	Fossen 型六自由度模型中的功率结构	15
1.4.2	理论模板与工程化 AUV 建模的差异	16
1.4.3	端口哈密顿表述的适用边界	16
1.4.4	从事后结构分析到事前结构约束	17
1.5	结构化连续时间动力学模型	17
1.5.1	SE(3) 运动学	18
1.5.2	相对动量与机械存储函数	18
1.5.3	势能诱导的保守广义力	19
1.5.4	非保守广义力与执行器通道	19
1.5.5	相对动量动力学	20
1.6	结构化模型的能量性质与功率关系	21
1.6.1	六自由度机械子系统与存储函数	21
1.6.2	耗散、零功率耦合与广义力功率	22
1.6.3	静水条件下的功率平衡命题和证明	22
1.6.4	海流、执行器与增强状态的适用范围	23

1.7	训练目标、基线体系与验证协议	24
1.7.1	结构保持参数化	24
1.7.2	控制块训练目标	25
1.7.3	长期递推与证据口径	25
1.7.4	基线模型与结构消融链条	26
1.7.5	结构消融设置	26
1.8	实验结果与结构证据分析	27
1.9	讨论	27
1.10	本章小结	28

第一章 面向长期状态预测的 AUV 结构化神经动力学建模方法

1.1 研究问题与方法概述

自主水下航行器 (autonomous underwater vehicle, AUV) 已广泛用于海底测绘、地球物理调查、海洋观测和工程巡检等任务 (Wynn et al., 2014; Sahoo et al., 2019)。在这类任务中, 航行器需要在受控推进、环境扰动和姿态变化共同作用下持续运动。为了支持任务规划、控制器设计、仿真评估和异常诊断, 模型不仅要解释当前运动状态如何变化, 还要能够在给定初始状态、控制输入和环境条件的情况下, 预测未来一段时间内的位置、姿态和速度等运动状态。因此, 本章所讨论的“长期状态预测”不是泛指任意输出的时间序列外推, 而是指受控 AUV 运动状态在长时域内的自由递推预测; 验证时模型需要把自身预测状态继续作为后续初值, 而不是只在真实历史状态条件下做单步拟合。

长期状态预测对运动模型提出了高于短时拟合的要求。短时预测误差主要反映模型对局部状态变化的逼近能力, 而长时域递推会不断把模型输出重新作为后续初值, 使局部误差、姿态偏差和控制响应偏差在轨迹中反复积累。一个模型即使在单个采样间隔内误差较小, 也可能在多步递推后产生明显的位置漂移、姿态不一致或速度发散。因此, AUV 运动建模不能只追求输入-输出函数逼近精度, 还需要关注模型所诱导的运动演化是否与受控动力学的基本约束相容。

传统 AUV 运动建模以参数化六自由度动力学为主线。Fossen 型模型为航行器运动提供了统一的坐标、速度、受力和控制表述, 并已成为仿真、控制和稳定性分析中的重要基础 (Fossen, 2011, 2021)。具体平台模型通常在这一框架下结合平台参数和水动力系数, 形成可计算、可解释的运动系统 (Presterio, 2001)。这类模型的优势在于物理含义清楚, 便于把运动预测、控制设计和工程诊断联系起来。其困难也很明确: 复杂水动力、平台参数和环境扰动往往需要通过计算流体力学、模型试验或系统辨识进行估计, 所得模型的适用范围受工况覆盖、实验成本和数据质量制约 (Phillips et al., 2010; Caccia et al., 2000; Panda et al., 2021; Ahmed et al., 2023)。

数据驱动方法为 AUV 运动建模提供了互补思路。神经网络可以从轨迹数据中学习复杂输入-输出关系, 弱化对完整显式参数模型的依赖, 并可用于状态转移、序列预

测或残差动力学建模。已有研究已经将神经网络用于 AUV 导航变量预测、解耦航向和深度响应建模以及物理信息约束的 AUV 动力学学习 (Song et al., 2020; Ertogan and Wilson, 2024; Zhao et al., 2024)。这类方法说明, 轨迹数据中包含可学习的动力学信息; 同时也表明, 若模型主要依赖非结构化映射、局部分量预测或方程残差约束, 则在短时拟合中虽可取得较小误差, 但姿态几何一致性、能量耗散趋势以及控制输入与机械功率之间的关系缺少足够约束, 这些不一致会在长期自由递推中被放大。

因此, AUV 数据驱动建模的关键问题不只是如何提高模型容量, 而是如何在可学习模型中保留能够约束长期演化的物理结构。结构化神经动力学为这一目标提供了方法基础。神经常微分方程 (Neural ODE) 通过连续时间向量场描述状态演化, 为受控系统建模和变步长积分提供了自然形式 (Chen et al., 2018); 物理信息机器学习和通用微分方程强调将已知机理与可学习函数结合 (Raissi et al., 2019; Karniadakis et al., 2021; Rackauckas et al., 2020); 哈密顿和端口哈密顿相关神经模型则将能量函数、耗散和输入端口引入学习动力学中 (Greydanus et al., 2019; van der Schaft and Jeltsema, 2014; van der Schaft, 2017)。这些思想并不直接给出完整的 AUV 工程模型, 但它们提供了一条折中路径: 用已知物理关系限制模型假设空间, 同时把难以显式建模的非线性作用留给数据驱动部分表达。

面向 AUV 运动状态的长期递推, 上述通用思想仍需要转化为适合水下航行器的模型形式。一方面, AUV 是受控开放系统, 模型需要描述推进器、舵面、海流和其他外部作用对运动状态的影响; 另一方面, AUV 运动具有明确的刚体运动、速度参照系和机械能量背景, 不能简单等同于普通欧氏空间中的非结构化序列。参数化六自由度模型、非结构化神经预测模型、方程残差约束模型以及哈密顿或端口哈密顿神经模型分别覆盖了这一问题的不同侧面; 对于长期状态预测, 更关键的是形成一种受控连续时间学习表述, 在同一框架中组织 $SE(3)$ 位姿几何、海流条件下的速度表示、机械能量与耗散结构、外部广义力功率解释, 并用长期自由递推而非仅用短时误差检验这些结构是否有效。

基于这一问题, 本章提出一种面向长期状态预测的 AUV 结构化神经动力学建模方法。该方法不是构造一个纯非结构化预测器, 也不是声称得到完整闭合的哈密顿或端口哈密顿物理系统; 它的目标是在受控连续时间向量场中组织 AUV 已知运动结构, 并用可学习部分表达难以显式参数化的非线性作用。为行文简洁, 下文将该模型简称为 AUVHamNODE; 其中“Ham”指机械核心采用的哈密顿式能量存储结构, 而非对完整系统作闭合哈密顿或端口哈密顿的声称。该方法的核心是将长期状态预测重新表述为受控连续时间动力学学习问题: 模型构造用于限制假设空间, 训练和验证协议用于检验这些结构约束是否改善 AUV 运动状态的长期递推行为。

上述定位构成本章从问题定义、模型构造到证据检验的论证链。在这一论证链中, 状态表示用于界定预测变量和速度参照系, 模型构造用于把几何、能量与功率关系写入连续时间向量场, 训练与长期递推验证则用于检验这些结构约束的实际作用。

概括而言, 本章的主要工作包括四个方面。其一, 把受海流影响的 AUV 长期状态

预测重新表述为增强状态上的受控连续时间动力学学习问题，并明确总体速度与相对水速度之间的状态契约。其二，构造一个在 $SE(3)$ 上保持位姿几何、以相对动量组织机械存储、并把非保守作用分解为耗散、零功率耦合和执行器驱动广义力的结构化神经向量场。其三，在限定条件下给出该模型机械核心的能量-功率平衡性质，并明确其相对完整航行器-执行器-环境系统的适用边界。其四，建立以长期自由递推、结构消融、初值扰动和内部物理诊断为核心的验证协议，用于检验结构约束是否改善长期预测行为。本文不预设结构化模型必然优于所有替代方案，而是把模型声称限定在可构造、可分析和可检验的范围内。本章其余部分依次展开相关建模基础、受控状态与海流速度约定、从 Fossen 能量结构到结构保持学习模型的过渡、结构化连续时间模型及其能量性质，以及训练验证协议与实验证据分析。

1.2 相关建模基础

AUVHamNODE 的模型构造需要同时连接两类基础。第一类来自海洋航行器动力学，它把位置、姿态、体坐标速度、质量、阻尼、恢复力和广义力组织为六自由度运动方程，并给出机械系统的能量-功率关系。第二类来自连续时间学习和结构化神经动力学，它把轨迹预测表述为受控初值问题，并用几何、能量、耗散或端口功率结构限制可学习向量场。这些基础共同支撑数据态与模型态的速度表示、结构化向量场构造和能量边界分析。连续时间学习部分保留较一般的受控流语言；在本文模型中，控制命令、海流和深度上下文则具体表示为增强状态中的分段常值外源变量，并与数据态、模型态和海流速度约定共同定义受控初值问题。

1.2.1 AUV 六自由度运动与能量-功率关系

AUV 运动通常以惯性坐标系或导航坐标系 n 和航行器体坐标系 b 共同描述。位置 $x \in \mathbb{R}^3$ 在惯性系中表达，姿态可由欧拉角等局部坐标表示，也可由旋转矩阵 $R \in SO(3)$ 表示。体坐标速度由线速度和角速度组成，记为

$$\nu = \begin{bmatrix} v \\ \omega \end{bmatrix} \in \mathbb{R}^6. \quad (1.1)$$

在局部姿态坐标 $\eta = [x^\top, \vartheta^\top]^\top$ 下，海洋航行器运动学常写为

$$\dot{\eta} = J_\eta(\eta)\nu, \quad (1.2)$$

其中 $J_\eta(\eta)$ 将体坐标速度转换为位置和姿态坐标导数 (Fossen, 2011, 2021)。局部姿态坐标便于与传统控制和仿真框架衔接，但可能引入坐标奇异性或参数化依赖。若直接使用旋转矩阵，则刚体运动学可写为

$$\dot{x} = Rv, \quad \dot{R} = R\hat{\omega}, \quad (1.3)$$

其中 $\hat{\omega} \in \mathfrak{so}(3)$ 是角速度对应的反对称矩阵。该形式使姿态导数位于 $SO(3)$ 的切空间方向上, 体现了旋转群约束本身是机械系统结构信息, 而不是普通欧氏状态上的附加正则项 (Bullo and Lewis, 2004; Hairer et al., 2006)。

Fossen 型海洋航行器动力学把 AUV 的惯性、水动力、恢复力和控制作用组织在统一的六自由度方程中 (Fossen, 2011, 2021)。在体坐标速度 ν 下, 其常见形式为

$$M\dot{\nu} + C(\nu)\nu + D(\nu)\nu + g(\eta) = \tau, \quad (1.4)$$

其中 $M = M_{RB} + M_A \succ 0$ 包含刚体质量和附加质量, $C(\nu) = C_{RB}(\nu) + C_A(\nu)$ 表示刚体与附加质量相关的 Coriolis/向心项, $D(\nu)$ 表示线性或非线性水动力阻尼, $g(\eta)$ 表示重力和浮力恢复项, τ 表示推进器、舵面或外部作用产生的广义力和广义力矩。

式 (1.4) 的价值不只在于给出加速度计算公式, 更在于它提供了机械系统的能量-功率平衡关系。在静水条件下, 或在外源速度已被纳入相对速度表示的六自由度机械子系统中, 若 $C(\nu)$ 满足零功率性质

$$\nu^\top C(\nu)\nu = 0, \quad (1.5)$$

阻尼满足 $D(\nu) \succeq 0$, 恢复力与势能 $V(\eta)$ 满足功率配对 $\dot{V} = \nu^\top g(\eta)$, 则机械能

$$H(\eta, \nu) = \frac{1}{2} \nu^\top M \nu + V(\eta) \quad (1.6)$$

在常正定质量矩阵或相应能量配对条件下满足

$$\dot{H} = \nu^\top \tau - \nu^\top D(\nu)\nu. \quad (1.7)$$

这说明质量矩阵定义动能, 恢复力对应势能, Coriolis/向心项只重分配动量而不做净功, 阻尼消耗机械能, 外部广义力通过 $\nu^\top \tau$ 与机械系统交换功率。式 (1.7) 是六自由度机械子系统层面的功率平衡关系, 不自动覆盖执行器内部储能、外源海流变量或未显式建模的环境动力学。

上述功率平衡关系依赖明确的速度变量和储能变量: 动能中的速度、阻尼中的速度和外部广义力的功率配对必须使用同一机械变量; 恢复力必须与同一个势能函数配对; 执行器状态、海流和其他环境量若没有独立储能定义, 就只能作为外源变量或广义力条件变量处理。这一依赖关系也决定了能量结构只能在定义清楚的六自由度机械子系统上讨论, 而难以直接推广到包含执行器内部状态和外源环境的完整系统。

这一功率平衡关系还区分了控制命令与广义力两个层次。在式 (1.4) 中, τ 已经是进入六自由度动力学的广义力; 推进器转速、舵角、控制器输出或期望命令通常还要经过执行器动态、饱和、舵桨效率和流体相互作用, 才转化为机械方程中的广义力。该层级区分是后文区分控制命令与执行器状态的物理依据。

1.2.2 水动力参数获取与模型校准边界

式 (1.4) 中的附加质量、阻尼、恢复力参数和执行器广义力模型通常无法仅由刚体几何直接确定。AUV 水动力系数可通过解析或半经验估计、计算流体力学 (computational

fluid dynamics, CFD)、约束模型试验、自由航行试验和系统辨识等路线获得 (Panda et al., 2021; Ahmed et al., 2023)。解析和半经验公式适合早期估计, CFD 可用于比较外形、舵面和推进布局对阻力或控制力的影响 (Phillips et al., 2010), 模型试验能够在特定操纵和速度条件下测量力和力矩, 系统辨识则利用实际或仿真输入-输出数据反推参数 (Caccia et al., 2000; Prestero, 2001)。

具体到六自由度模型, 需要估计或校准的对象不仅包括纵向、横向和垂向阻尼系数, 还包括附加质量矩阵中的耦合项、角速度相关力矩、二次阻力、升力或横流阻力、舵面与推进器产生的控制导数, 以及重心和浮心偏置引起的恢复力参数。这些项具有明显的工况依赖性: 大攻角、低速操纵、近海底运动、非均匀海流或推进器入流变化都可能改变广义力模型, 使同一组名义参数在不同速度、深度或姿态区间表现出不同误差。

不同参数获取路线也有各自边界。CFD 结果受网格、湍流模型、边界条件和计算成本影响, 仍需实验或航行数据校准; 约束试验覆盖的运动工况有限; 自由航行试验更接近实际任务, 但会同时混入控制器闭环、传感器误差、执行器非理想性和环境扰动。近年来, AI 辅助水动力系数估计和数据驱动残差建模进一步扩展了传统路线 (Ahmed et al., 2023; Macatangay et al., 2024)。已有工作使用神经网络增强水下航行器模型辨识 (van de Ven et al., 2007), 用支持向量机辨识水下航行器非线性动力学 (Xu et al., 2013), 也用多输出高斯过程进行非参数动力学辨识 (Ariza Ramirez et al., 2021)。这类方法降低了显式参数化负担, 但并不能消除水动力辨识中的非唯一性: 同一轨迹误差可能由附加质量、阻尼、舵桨效率、未建模执行器动态、海流估计误差或控制输入偏差的不同组合共同造成。因此, AUVHamNODE 中的神经分支被解释为结构诱导的非保守广义力假设空间, 而不是逐项唯一恢复真实水动力机理。

1.2.3 受控时序预测与连续时间动力学学习

从机器学习角度看, AUV 运动预测可以首先写成受控时序映射。设 s_k 表示离散采样时刻的状态, u_k 表示控制输入, c_k 表示海流、深度或任务上下文, 则多步预测可表示为

$$\hat{s}_{k+1:k+H} = \mathcal{F}_\theta(s_{0:k}, u_{0:k+H-1}, c_{0:k+H-1}), \quad (1.8)$$

也可用单步状态转移递推表示为

$$\hat{s}_{k+1} = F_\theta(s_k, u_k, c_k). \quad (1.9)$$

已有 AUV 研究已经利用神经网络处理导航变量预测、运动响应建模、动态定位控制和轨迹预测等问题 (Song et al., 2020; Ertogan and Wilson, 2024; Yao et al., 2024), 物理信息约束也被用于水下航行器动力学学习 (Zhao et al., 2024)。这些工作说明轨迹数据中包含可学习的动力学信息, 也说明神经模型可以作为传统建模与控制方法的补充。

非结构化离散时序模型具有训练目标直接、实现成本低和表达能力强等优点, 但其局限在长期递推中更加明显。首先, 单步转移通常与固定采样间隔绑定, 模型学习

到的是特定时间步长下的状态映射，而不是独立于采样频率的连续时间向量场。其次，训练阶段常用真实历史状态作为输入，长期验证阶段却必须把预测状态反馈为下一步初值，局部误差会在自由递推中被反复放大。最后，普通离散映射通常不显式区分位置运动学、姿态约束、速度参照系、能量耗散和控制功率；对于 AUV 这类受控机械系统，这些缺失会使短时拟合误差与长时域运动一致性之间出现偏差。

神经常微分方程 (Neural ODE) 将状态演化写成可学习连续时间向量场 (Chen et al., 2018):

$$\dot{y} = f_{\theta}(y, t), \quad \hat{y}(t) = y(t_0) + \int_{t_0}^t f_{\theta}(y(\tau), \tau) d\tau. \quad (1.10)$$

对受控 AUV 运动，向量场还必须依赖控制命令、执行器状态或环境上下文，可写为

$$\dot{y} = f_{\theta}(y(t), u(t), c(t), t), \quad \hat{y}(t_i) = \Phi_{\theta}(t_i; t_0, y_0, u, c), \quad (1.11)$$

其中 Φ_{θ} 表示由可学习向量场和输入函数共同诱导的流映射。若外部信号以不规则采样或连续路径形式给出，也可采用神经控制微分方程 (Neural Controlled Differential Equation, Neural CDE) 等路径驱动连续时间模型 (Kidger et al., 2020); 本文采用更直接的分段控制块和外源上下文表述。

式 (1.11) 是受控连续时间学习的一般写法。本文的具体模型将控制命令、海流速度和深度上下文并入增强状态，并在单个求解窗口内作为分段常值外源变量处理；向量场对外部信号的依赖因此体现为对这些外源变量和执行器状态的条件化。这一区分使一般受控流表述能够与本文的状态空间定义一致，而不把外部信号误写成独立闭合的环境动力学。

执行器动态是受控连续时间学习与 AUV 建模结合时必须处理的环节。推进器或舵面命令通常不是瞬时广义力，命令到实际作用之间存在滞后、限幅和非线性映射；这也与 Fossen 型建模中控制输入需要通过推进器、舵面或控制分配模型转化为六自由度广义力的处理相一致 (Fossen, 2011, 2021)。将执行器状态 u_a 纳入增强状态后，可以写成

$$\dot{y}_{\text{mech}} = f_{\theta}(y_{\text{mech}}, u_a, c), \quad \dot{u}_a = f_{\theta}^a(u_a, u_c). \quad (1.12)$$

这种写法使控制命令、执行器状态和实际广义力之间的层级关系可以在连续时间模型中表达，而不是被隐含吸收到单步预测误差中。

神经常微分方程提供的是连续时间动力学学习框架，本身并不保证物理一致性。给定同一向量场，积分步长、误差容差和求解器类型会影响离散输出；在长期递推中，向量场模型误差、数值积分误差和自由递推误差还会相互放大。因而，若可学习向量场本身没有几何、能量和功率结构，它仍可能产生姿态漂移、速度发散或难以解释的能量变化。几何数值积分研究进一步表明，严格保持李群结构、辛结构或能量结构通常需要专门的结构保持积分器，例如流形与李群上的 Runge-Kutta 方法以及辛/变分积分方法 (Munthe-Kaas, 1999; Iserles et al., 2000; Hairer et al., 2006)。本文模型在连续时间向量场层面编码 SE(3) 结构，但默认使用通用显式求解器，因此把姿态正交性和能量诊断作为长期递推评估的一部分，而不假设普通求解器严格保持群结构。

1.2.4 科学机器学习与结构化动力学先验

科学机器学习强调学习型微分方程不应只依赖数据拟合，还应把可信的先验结构写入模型。物理信息神经网络通过方程残差、边界条件和数据项联合训练模型 (Raissi et al., 2019)；物理信息机器学习更广泛地讨论了数据驱动方法与守恒律、对称性和多尺度机理的结合 (Karniadakis et al., 2021)；通用微分方程则把已知微分方程项和未知神经项组合在同一连续时间模型中 (Rackauckas et al., 2020)。在水下航行器场景中，物理信息网络和物理引导混合网络 (physics-guided hybrid network) 已被用于动力学建模和水动力参数辨识 (Zhao et al., 2024; Fei et al., 2026)。这些方法为 AUV 建模提供了重要启发：已知物理关系可以作为模型结构和训练目标的一部分，而难以显式闭合的作用可以由可学习项表达。

不过，对 AUV 长期状态预测而言，通用的方程残差或混合项并不能自动覆盖所有关键结构。首先，姿态变量属于 $SO(3)$ ，长期递推需要处理旋转群几何一致性。其次，水动力阻尼和非保守作用应与机械能量变化相容，耗散项不应无约束地产生能量。再次，推进器、舵面和外部扰动力矩进入机械方程时应按广义力-速度功率配对解释，而控制命令本身通常还不是功率端口变量。最后，有海流时，位置运动学与水动力广义力依赖的速度表示并不相同；总体速度和相对水速度的区分必须进入状态表示。哈密顿和端口哈密顿结构为这些能量与功率约束提供了更具体的组织方式。

1.2.5 哈密顿与端口哈密顿结构化建模基础

哈密顿力学以能量函数为中心描述机械系统 (Arnold, 1989)。设 $q \in \mathbb{R}^n$ 为广义坐标， $p \in \mathbb{R}^n$ 为共轭动量。对典型机械系统，哈密顿量可写为

$$H(q, p) = \frac{1}{2} p^\top M(q)^{-1} p + V(q), \quad \frac{\partial H}{\partial p} = M(q)^{-1} p. \quad (1.13)$$

在正则坐标中，哈密顿方程具有斜对称结构

$$\dot{z} = J \nabla H(z), \quad J = -J^\top, \quad (1.14)$$

其中 $z = [q^\top, p^\top]^\top$ 。由于 J 斜对称，连续时间精确流满足 $\dot{H} = \nabla H^\top J \nabla H = 0$ 。因此，能量守恒不是由“存在一个标量函数”单独产生的，而是由能量梯度和斜对称互连结构共同产生的。

哈密顿神经网络 (Hamiltonian Neural Network, HNN) 将这一思想用于神经动力学学习 (Greydanus et al., 2019)：模型不直接拟合任意 $\dot{z}$ ，而是学习标量能量函数 $H_\theta(z)$ ，再由结构方程生成向量场。后续 SymODEN 和 Dissipative SymODEN 进一步把控制、耗散和不可直接观测动量纳入结构化学习框架 (Zhong et al., 2020b,a)。对 AUV 建模而言，本文借鉴的不是闭合保守系统的能量守恒假设，而是“机械存储函数 + 受限结构生成向量场”的建模原则；AUV 本身是受控开放系统，存在阻尼、推进器和舵面输入、海流影响、执行器滞后以及环境扰动。

端口哈密顿系统把哈密顿能量方法扩展到开放、耗散和受控系统 (van der Schaft and Jeltsema, 2014; van der Schaft, 2017)。有限维端口哈密顿系统常写为

$$\dot{z} = (J(z) - \mathcal{R}(z))\nabla H(z) + G(z)u, \quad J(z) = -J(z)^\top, \quad \mathcal{R}(z) \succeq 0. \quad (1.15)$$

若定义端口输出 $y = G(z)^\top \nabla H(z)$, 则存储函数满足

$$\dot{H} = -\nabla H(z)^\top \mathcal{R}(z) \nabla H(z) + y^\top u \leq y^\top u. \quad (1.16)$$

该不等式说明, 内部耗散不会自行增加存储能量, 能量增加必须通过外部端口功率解释。与 HNN 的保守情形不同, 端口哈密顿形式不要求能量守恒, 而要求能量变化来源能够由端口功率和内部耗散共同解释。

机械系统的端口哈密顿形式与 Fossen 型功率结构存在自然联系: 动量变量下的机械存储函数给出速度映射, Coriolis/向心项可解释为零功率互连的一部分, 阻尼对应耗散, 推进器和舵面产生的广义力对应外部机械端口。因此, 式 (1.7) 可理解为海洋航行器动力学中的端口哈密顿风格功率平衡。但这一联系具有明确边界: 实际 AUV 模型还包含经验舵桨项、执行器限幅、控制器闭环、海流外源和未建模环境扰动。若没有为这些部分引入额外状态、端口和储能定义, 就不能把完整航行器-执行器-环境增强系统声称为闭合标准端口哈密顿系统。

端口哈密顿神经模型或端口哈密顿风格神经模型把 H 、 J 、 $\mathcal{R}$ 或 G 中的部分对象参数化为神经网络, 同时保留斜对称、正定耗散和端口功率结构。相关综述指出, 机器学习与端口哈密顿系统的结合主要围绕哈密顿学习、结构保持降阶、端口哈密顿实现和控制展开 (Cherifi, 2020)。已有 pHNN 和伪哈密顿神经模型还强调了外部力与内部结构的分离: 显式时变受迫系统和状态相关外部力都可以在哈密顿或端口哈密顿风格框架中建模 (Desai et al., 2021; Eidnes et al., 2023)。本文采用这些思想构造结构化连续时间假设空间, 但只把可证明的端口语义限定在开放式六自由度机械子系统及其广义力-速度功率配对上; 执行器状态、海流外源和由上下文驱动的非线性广义力分支在本文模型中作为受控开放系统的一部分处理。

在刚体与机器人动力学方向, 已有研究把哈密顿或拉格朗日结构直接嵌入神经动力学模型。深度拉格朗日网络和拉格朗日神经网络通过学习拉格朗日量约束模型输出 (Lutter et al., 2019; Cranmer et al., 2020), 并可借助显式约束进一步简化哈密顿与拉格朗日神经网络 (Finzi et al., 2020)。与本文最接近的是在 SE(3) 流形上构造的哈密顿与端口哈密顿 Neural ODE: 它们以正定逆质量、势能和输入项参数化刚体能量结构, 并用于位姿动力学学习与控制 (Duong and Atanasov, 2021; Duong et al., 2024)。本文与这一系列工作共享 SE(3) 几何与能量结构化神经动力学的基本思路, 差异在于面向受海流影响的水下航行器长期状态预测: 其一, 引入总体速度与相对水速度的状态契约 (见第 1.3 节), 使机械功率配对在有海流条件下仍保持一致; 其二, 显式建模命令到广义力之间的一阶执行器滞后通道, 而非把控制输入直接当作理想广义力或标准仿射输入; 其三, 把端口哈密顿语义严格限定在开放式六自由度机械子系统, 而不声称

完整航行器-执行器-环境系统闭合；其四，以长期自由递推、结构消融和内部物理诊断作为主要证据，而不仅依赖短时拟合误差或闭环控制性能。

1.2.6 相关基础小结与本文建模需求

上述基础共同指向本文模型需要处理的三个问题。首先，Fossen 型六自由度动力学给出了 AUV 运动中的能量-功率平衡关系，但复杂水动力、执行器作用和环境扰动使完整参数化模型难以在所有工况下闭合。其次，神经常微分方程将轨迹预测表述为受控连续时间初值问题，适合长期递推和不同控制块长度下的动力学学习，但非结构化向量场本身不保证姿态几何、能量耗散和功率配对的一致性。最后，哈密顿和端口哈密顿思想提供了机械存储、耗散、零功率互连和外部功率端口的组织方式，但这些结构必须限定在可定义、可分析的机械子系统内使用。

从文献角色看，参数化六自由度模型提供坐标、速度和功率结构；水动力辨识和数据驱动残差建模说明难以闭合项可以由数据补充，但不能消除可辨识性边界；非结构化时序预测和 Neural ODE 提供轨迹学习形式，却不自动包含姿态、能量和功率约束；物理信息学习、HNN 与端口哈密顿神经模型提供结构化先验，但需要转化到 AUV 受控开放系统、海流速度表示和长期自由递推验证中。由此，数据态与模型态之间的速度表示，特别是海流条件下总体速度和相对水速度的关系，构成模型定义的前提；融合 SE(3) 运动学、相对动量、机械存储函数、耗散和非保守广义力的连续时间向量场构成假设空间；六自由度机械子系统的能量平衡与长期递推验证协议共同限定并检验这些结构约束对 AUV 运动状态预测的作用。

表 1.1: 相关建模基础在本文论证中的角色

文献与方法家族	相关基础	本文建模需求
六自由度参数化模型与平台仿真	坐标、速度、质量、阻尼、恢复力和广义力的能量-功率关系	复杂水动力和执行器作用难以在所有工况下显式闭合。
水动力辨识与数据驱动残差模型	说明未知广义力和参数误差可以由数据补充	不保证附加质量、阻尼、舵桨效率和海流误差等来源被唯一辨识。
非结构化受控时序预测与 Neural ODE	给出从轨迹数据学习状态演化和长期递推的形式	非结构化向量场不自动保证姿态几何、速度表示、能量耗散和功率配对一致。
物理信息学习、HNN 与端口哈密顿神经模型	提供将能量、耗散、互连和外部功率写入可学习模型的结构先验	需要转化到 AUV 受控开放系统、海流相对速度和可验证机械子系统边界。

1.3 受控状态表示与海流速度约定

将 AUV 运动写成结构化连续时间模型之前，必须先固定数据空间和模型空间的状态表示。第 1.2 节已经说明，海洋航行器动力学中的位置运动学、速度参照系和水动力广义力具有不同物理角色。若有海流时仍把数据保存速度、模型内部速度和输出评估速度混为同一变量，SE(3) 运动学、机械存储函数、训练损失和长期递推指标都会失去一致解释。因此，受控状态、海流速度转换和初值问题定义不是独立于模型之外的记号安排，而是本文方法在有海流场景下保持惯性运动和水动力建模一致性的状态表示约定。

1.3.1 坐标系、状态与控制

设 n 表示惯性坐标系或导航坐标系， b 表示航行器体坐标系。航行器配置变量定义为

$$q = (x, R), \quad x \in \mathbb{R}^3, \quad R \in \text{SO}(3), \quad (1.17)$$

其中 R 将体坐标系向量映射到惯性坐标系。本文训练数据以控制块为基本单位， x 表示以该控制块初始位置为原点的惯性系相对位移；其时间导数仍等于航行器相对于惯性系的总体线速度。若势能或上下文特征需要绝对深度，则由块初始深度 z_{ref} 与相对垂向位移共同重构，而不是把数据态中的 x 直接解释为全局绝对位置。体坐标系角速度记为 $\omega \in \mathbb{R}^3$ 。执行器命令记为 $u_c \in \mathbb{R}^m$ ，实际执行器状态记为 $u_a \in \mathbb{R}^m$ 。二者具有不同物理含义： u_c 是控制器或数据集给出的命令， u_a 是经过执行器动态后的内部状态，并作为广义力分支的输入之一。

一个训练或验证控制块由采样时刻 $\{t_i\}_{i=0}^T$ 上的状态序列组成。数据空间保存可观测或可重建的轨迹状态，本文记为

$$s_i = [x_i, \text{vec}(R_i), \nu_{b,i}, u_{a,i}, u_{c,i}, v_{c,i}^n, z_{\text{ref}}] \quad (1.18)$$

表示。这里 $v_c^n \in \mathbb{R}^3$ 为惯性系海流速度， $z_{\text{ref}} \in \mathbb{R}$ 为可选块初始深度上下文；无海流数据可令 $v_c^n = 0$ ，无绝对深度上下文的数据可省略 z_{ref} 。向量化符号 $\text{vec}(R)$ 仅表示存储格式；数学上姿态变量仍受 $R \in \text{SO}(3)$ 约束。数据态 s_i 的速度分量采用总体速度表示。各分量维度为：位置 $x \in \mathbb{R}^3$ 、向量化旋转 $\text{vec}(R) \in \mathbb{R}^9$ 、体坐标总体速度 $\nu_b \in \mathbb{R}^6$ 、执行器状态 $u_a \in \mathbb{R}^m$ 、执行器命令 $u_c \in \mathbb{R}^m$ 、惯性系海流 $v_c^n \in \mathbb{R}^3$ 和深度上下文 $z_{\text{ref}} \in \mathbb{R}$ ，因此完整数据态维数为 $22 + 2m$ ，省略可选海流或深度通道时相应减少。

式 (1.18) 描述的是本文仿真数据和基准评估中可保存、可重构或由仿真器直接给出的状态变量。真实海试条件下，实际执行器状态、局部海流速度或绝对深度上下文可能来自估计器、传感器融合或外部海况模型，其观测误差和可用性属于真实数据泛化问题，而不由本章的仿真状态定义自动解决。

1.3.2 总体速度与相对水速度

有海流时, 航行器相对于惯性系的总体速度 (over-ground velocity) 与相对于周围水体的速度不同。总体速度描述航行器位姿在惯性系中的变化; 相对水速度 (through-water velocity) 描述航行器相对于局部水体的运动, 并在本文水动力建模假设下用于参数化阻尼、升力和横向水动力等非保守广义力。本文采用局部平移海流近似: 在一个状态样本或控制块内, 海流以惯性系向量 $v_c^n \in \mathbb{R}^3$ 作为外源变量, 用于速度转换和可选广义力特征; 海流的空间梯度、剪切、涡量和环境自身动力学不在本章模型中闭合描述。该近似在海流空间尺度远大于航行器特征尺度、且单个控制块时窗内海流近似定常时较为合理; 强剪切、近壁面或快速时变流场超出其适用范围, 相关泛化局限在第 1.9 节讨论。令惯性系海流速度为 v_c^n , 则体坐标系海流速度为

$$v_c^b = R^\top v_c^n. \quad (1.19)$$

数据空间中的体坐标系总体速度记为

$$\nu_b = \begin{bmatrix} v_b \\ \omega \end{bmatrix}, \quad (1.20)$$

其中 $v_b \in \mathbb{R}^3$ 是航行器相对于惯性系运动的体坐标系线速度, $\omega \in \mathbb{R}^3$ 是体坐标系角速度。模型内部用于水动力相关广义力计算的相对水速度记为

$$\nu_r = \begin{bmatrix} v_r \\ \omega \end{bmatrix}, \quad v_r = v_b - v_c^b. \quad (1.21)$$

在上述局部平移海流近似下, 海流只改变线速度参照系, 不改变体坐标系角速度。因此, 数据空间和模型空间之间的速度关系为

$$\nu_r = \nu_b - \begin{bmatrix} R^\top v_c^n \\ 0 \end{bmatrix}, \quad \nu_b = \nu_r + \begin{bmatrix} R^\top v_c^n \\ 0 \end{bmatrix}. \quad (1.22)$$

无海流时可取 $v_c^n = 0$, 式 (1.22) 退化为 $\nu_r = \nu_b$ 。上述变量关系保证位置运动学和水动力建模使用各自适合的速度表示: 位置 x 在惯性系中变化, 因此由总体速度推进; 阻尼、升力、横向耦合和执行器相关水动力主要依赖航行器相对于水体的运动, 因此由相对水速度参数化。对应的位置运动学可写为

$$\dot{x} = R v_b = R(v_r + R^\top v_c^n) = R v_r + v_c^n. \quad (1.23)$$

式 (1.23) 只说明线速度表示的转换, 本身并不定义姿态运动学或相对动量动力学; 这些方程必须与相同的速度约定相容。

假设 1.1 (状态表示与外源变量). 本文模型采用以下状态表示: R 始终表示体坐标系到惯性坐标系的旋转; 数据态速度分量保存体坐标系总体速度 ν_b , 模型态速度分量保存相对水速度 ν_r ; 局部海流以惯性系平移速度 v_c^n 表示, 并通过 $R^\top v_c^n$ 转换到体坐标系; 该海流表示只平移线速度, 不改变体坐标角速度。控制命令 u_c 、海流 v_c^n 和深度上下文 z_{ref} 在单个求解窗口内作为分段常值外源变量处理, 其导数置零; 实际执行器状态 u_a 则按照一阶滞后动力学演化, 并作为广义力分支的条件变量。

1.3.3 数据态、模型态与受控初值问题

训练数据保存总体速度表示下的状态

$$s = [x, R, \nu_b, u_a, u_c, v_c^n, z_{\text{ref}}], \quad s \in \mathcal{S}_d, \quad (1.24)$$

神经常微分方程使用相对水速度表示下的增强状态

$$y = [x, R, \nu_r, u_a, u_c, v_c^n, z_{\text{ref}}], \quad y \in \mathcal{S}_m. \quad (1.25)$$

其中 $\mathcal{S}_d$ 和 $\mathcal{S}_m$ 分别表示数据态空间和模型态空间；二者在块内相对位置、姿态、执行器状态、命令和外源变量上共享同一数值，只在线速度表示上不同。为简化记号，定义

$$\Delta_c(R, v_c^n) = \begin{bmatrix} R^\top v_c^n \\ 0 \end{bmatrix}. \quad (1.26)$$

则数据态到模型态的映射为

$$\mathcal{T}_{d \rightarrow m}(s) = [x, R, \nu_b - \Delta_c(R, v_c^n), u_a, u_c, v_c^n, z_{\text{ref}}], \quad (1.27)$$

模型态到数据态的映射为

$$\mathcal{T}_{m \rightarrow d}(y) = [x, R, \nu_r + \Delta_c(R, v_c^n), u_a, u_c, v_c^n, z_{\text{ref}}]. \quad (1.28)$$

图 1.1 概括了这两个状态空间、双向映射及相应速度变量的使用方式。




图 1.1: 海流条件下数据/评估空间与 ODE 模型空间之间的速度表示转换。数据/评估空间保留总体速度，ODE 模型空间使用相对水速度；训练中的速度监督在模型空间进行，输出报告和外部任务评估前再恢复总体速度。

由此，受控轨迹预测任务可表述为一个带状态转换的连续时间初值问题。给定初始数据态 s_0 ，控制块内的命令和外源变量写入增强状态中的 u_c 、 v_c^n 和 z_{ref} ，并在该积分窗口内按分段常值处理。先将初值转换为模型态

$$y_0 = \mathcal{T}_{d \rightarrow m}(s_0). \quad (1.29)$$

神经常微分方程在模型态空间中产生连续时间流

$$\hat{y}(t_i) = \Phi_\theta(t_i; t_0, y_0), \quad i = 0, \dots, T, \quad (1.30)$$

其中 Φ_θ 是包含执行器状态、命令变量和外源变量的增强状态流；由于 u_c 、 v_c^n 和 z_{ref} 已包含在 y_0 中并在窗口内取零导数，上式不再把它们重复写成额外函数参数。再通过输出映射回到数据空间

$$\hat{s}_i = \mathcal{T}_{m \rightarrow d}(\hat{y}(t_i)). \quad (1.31)$$

训练监督和结果报告使用不同但一致的变量表示。训练时，位置、姿态和执行器状态在数据态和模型态中数值相同，速度项则将目标轨迹和预测轨迹共同转换到模型空间后比较 ν_r ，以避免有海流样本把相对水速度误当成总体速度学习。评估和报告时，预测轨迹先通过 $\mathcal{T}_{m \rightarrow d}$ 恢复到数据空间，再报告位置、姿态、总体速度和执行器状态等可观测指标；相对水速度保留为模型空间诊断量，用于解释水动力建模变量是否一致。该约定使 SE(3) 运动学、机械能模型、训练损失和长期递推指标使用一致的状态表示。

1.4 从 Fossen 能量结构到结构保持学习模型

第 1.2 节已经说明，Fossen 型六自由度方程不仅是一组用于计算加速度的经验动力学方程，还隐含了机械能、耗散和广义力功率之间的结构关系。第 1.3 节进一步固定了本文在海流条件下使用的状态和速度表示。由此，进入模型构造的关键不是把某一具体工程仿真器逐项改写为标准端口哈密顿系统，而是把 Fossen 型动力学中的能量-功率角色转化为可训练函数类的结构约束：相对水速度参与机械存储、阻尼和广义力功率配对，总体速度负责位置运动学，控制命令、海流和深度上下文作为外源条件影响广义力计算与速度转换。

1.4.1 Fossen 型六自由度模型中的功率结构

第 1.2 节已经给出 Fossen 型六自由度动力学的能量-功率平衡关系式 (1.7)，并说明它与式 (1.15)–(1.16) 的端口哈密顿功率结构共享同一本功率账本：存储函数描述系统能量，斜对称结构不改变总能量，耗散结构不自行增能，外部作用通过广义力-速度功率配对改变存储能量。这里不重复该推导，只强调把这一结构用于本文模型时的一处关键特化。在第 1.3 节的海流速度约定下，六自由度机械子系统的存储、阻尼和广义力功率配对应以相对水速度 $\nu_r = [v_r^\top, \omega^\top]^\top$ 为机械速度变量，而位置运动学仍由总体速度推进。相应地，式 (1.7) 中的机械速度取 ν_r ，功率平衡写为

$$\dot{H} = \nu_r^\top \tau - \nu_r^\top D(\nu_r) \nu_r, \quad (1.32)$$

其中 τ 是已进入机械方程的广义力，而非控制命令本身；命令到广义力的映射需经执行器状态和水动力作用进一步建模。

这一功率账本视角对数据驱动建模有直接约束意义。如果学习模型只拟合状态导数或离散状态转移，就可能把阻尼、无功耦合和执行器广义力混入同一个非结构化向量场中；短时误差可以下降，但长期递推时可能出现难以解释的能量增长、速度发散或姿态漂移。相反，如果模型在函数类层面保留正定质量、标量势能、半正定耗散、斜对称零功率耦合和广义力-速度功率配对，就可以把 Fossen 型功率结构转化为对可学习动力学的先验限制。

1.4.2 理论模板与工程化 AUV 建模的差异

Fossen 型方程提供的是六自由度 AUV 运动的理论模板，而工程化 AUV 建模通常还要面对更具体的水动力、执行器和环境作用。附加质量、阻尼、升力、横流阻力、舵面效应和推进器作用往往依赖平台几何、航速、姿态、入流和试验覆盖范围，其解析表达和参数标定均存在工况边界 (Panda et al., 2021; Ahmed et al., 2023)。这些项可以在机械方程中表现为耗散、零功率耦合或外部广义力，但并不意味着每个经验项都能被唯一分解为真实物理机制，也不意味着完整工程化系统天然就是闭合标准端口哈密顿系统。

控制通道也具有同样的层次差异。推进器转速、舵角命令或控制分配输出通常不是直接进入机械方程的理想广义力；它们需要经过执行器滞后、限幅、舵桨效率、入流速度和流体耦合后，才形成六自由度广义力。海流也不是内部阻尼或保守力的一部分：它改变总体速度与相对水速度之间的关系，并可能在位置运动学和能量导数中引入外源功率交换。数值积分、姿态归一化、状态裁剪和控制饱和等处理对工程仿真和数据生成可以是必要的，但它们不属于标准连续端口哈密顿向量场本身。

1.4.3 端口哈密顿表述的适用边界

因此，合适的理论边界是区分六自由度机械子系统和完整航行器-执行器-环境增强系统。前者可以用能量存储、耗散、零功率耦合和广义力-速度功率配对描述；后者还包含执行器状态、外源海流、数值离散和工程约束，不能被不加限定地称为闭合标准端口哈密顿系统。本文的能量性质分析只针对六自由度机械子系统及其广义力-速度功率配对，而不声称完整增强系统满足严格闭合的端口哈密顿结构。

这一边界也限制了可学习模型的解释方式。耗散分支、零功率耦合分支和广义力分支提供的是物理诱导的结构化假设空间，而不是对真实水动力项的唯一辨识；执行器状态、海流速度和深度上下文可以条件化广义力或速度转换，但若没有额外储能和端口定义，就不应被并入闭合机械存储函数。这样的表述保留端口哈密顿语言中对能量来源的约束作用，同时避免把工程化 AUV 系统过度理想化。

1.4.4 从事后结构分析到事前结构约束

传统 Fossen-to-pH 分析通常从已有解析方程出发, 检查质量矩阵、Coriolis 项、阻尼、恢复力和输入端口是否满足端口哈密顿条件。其逻辑是先给出 M, C, D, g, τ , 再验证相应的存储函数、斜对称互连、耗散矩阵和端口功率关系是否成立。这样的分析能够解释已有模型为什么具有无源性或能量边界, 但它仍依赖人工给定的水动力结构、平台参数和执行器模型。

结构保持神经动力学采用相反的建模顺序。模型不先学习任意向量场再事后检查能量性质, 而是在定义可训练函数类时就嵌入结构约束: 用正定参数化生成质量或逆质量矩阵, 用标量函数生成势能和保守广义力, 用半正定参数化生成耗散矩阵, 用反对称参数化生成零功率耦合项, 并用执行器状态和环境上下文条件化可学习广义力分支。相关哈密顿和端口哈密顿神经模型已经表明, 能量函数、耗散结构和外部作用可以作为神经动力学的结构先验, 而不是仅作为训练后的诊断对象 (Greydanus et al., 2019; Desai et al., 2021; Eidnes et al., 2023; Cherifi, 2020)。由此, 神经网络负责表达难以解析闭合的非线性作用, 几何、耗散和功率角色则由模型结构本身限定。

这一转变不是从物理模型走向黑箱模型, 而是从固定参数物理模型走向结构保持的可学习物理模型。Fossen 型模型回答的是给定参数和经验公式后系统如何运动; 端口哈密顿分析回答的是这些方程背后的能量结构如何组织; AUVHamNODE 则把这种能量结构转化为可训练的连续时间假设空间, 在质量、势能、耗散、零功率耦合和广义力等结构角色上学习等效参数化对象, 同时保留第 1.3 节定义的总体速度-相对水速度契约。

由此得到本文模型构造的基本原则: 位姿运动学应在 $SE(3)$ 上表达, 机械存储函数应与相对水速度和相对动量配对, 非保守作用应区分耗散、零功率耦合和外部广义力, 控制命令应先经过执行器状态再进入广义力分支, 海流和深度上下文应作为外源变量参与速度转换和条件化, 而不是被并入闭合机械储能。基于这些原则, AUVHamNODE 的主体模型可以写成一个受控、开放、结构化的连续时间神经动力学模型。

1.5 结构化连续时间动力学模型

第 1.4 节给出的桥梁关系表明, 适合本文任务的学习模型不应只是状态导数的黑箱拟合器, 而应在连续时间向量场中保留 AUV 运动中较可靠的结构角色。AUVHamNODE 因此将长期状态预测表述为增强状态上的受控初值问题: 位姿由 $SE(3)$ 运动学推进, 机械速度采用第 1.3 节定义的相对水速度, 机械存储函数由正定质量和标量势能给出, 非保守作用则由耗散、零功率耦合和执行器驱动的可学习广义力共同表达。该构造不要求所有水动力项具有固定解析公式, 也不把执行器和海流并入闭合机械储能; 它的目标是在可训练函数类中保留几何、能量和功率角色。

在单个积分窗口内，模型态可写为

$$y = [x, R, \nu_r, u_a, u_c, v_c^n, z_{\text{ref}}], \quad (1.33)$$

其中 u_c 、 v_c^n 和 z_{ref} 是分段常值外源通道， u_a 是由命令驱动的一阶执行器状态。若某一实验设置不使用海流或深度上下文，相应通道从增强状态中省略。由于控制命令和外源上下文已经作为状态分量携带并在单个积分窗口内取零导数，模型可在增强状态 y 上写成自治形式的连续时间向量场

$$\dot{y} = F_\theta(y), \quad (1.34)$$

并通过 $\mathcal{T}_{d \rightarrow m}$ 与 $\mathcal{T}_{m \rightarrow d}$ 在数据空间和模型空间之间转换速度表示。该向量场由位姿运动学、机械存储、广义力分解和相对速度动力学共同确定。

1.5.1 SE(3) 运动学

AUVHamNODE 首先把位姿变化从可学习黑箱中分离出来，显式编码刚体运动学：

$$\dot{x} = Rv_b, \quad \dot{R} = R\hat{\omega}. \quad (1.35)$$

其中 $\hat{\omega} \in \mathfrak{so}(3)$ 表示角速度 ω 对应的反对称矩阵。式 (1.35) 使姿态导数位于旋转群的切空间方向，而不是由神经网络直接输出任意九维矩阵导数。海流条件下，位置运动学必须使用总体速度；由式 (1.22) 有 $v_b = v_r + R^\top v_c^n$ ，因此

$$\dot{x} = R(v_r + R^\top v_c^n) = Rv_r + v_c^n. \quad (1.36)$$

这一写法同时满足两个要求：位置相对于惯性系推进，水动力相关分支仍以相对水速度为主要机械变量。连续时间层面，若 $R(0) \in \text{SO}(3)$ ，则 $\dot{R} = R\hat{\omega}$ 与 $\text{SO}(3)$ 的切空间相容 (Bullo and Lewis, 2004; Hairer et al., 2006)；离散数值积分仍可能引入正交性和行列式漂移，因此这种运动学约束应理解为连续时间向量场结构，而不是普通 ODE 求解器的严格李群积分保证。

1.5.2 相对动量与机械存储函数

机械部分以相对水速度为功率配对变量。令

$$p_r = M_\theta \nu_r, \quad (1.37)$$

其中 $M_\theta \in \mathbb{R}^{6 \times 6}$ 为正定质量矩阵， p_r 为相对动量。机械存储函数定义为

$$H_\theta(q, p_r) = \frac{1}{2} p_r^\top M_\theta^{-1} p_r + V_\theta(q), \quad (1.38)$$

其中 $q = (x, R)$ ， $V_\theta(q)$ 为标量势能函数的简写。由于本文数据态中的位置 x 是控制块内相对位移，本文采用的参数化并不把 V_θ 解释为可任意依赖水平相对位置的全局

势能；其可学习输入应理解为与姿态重力方向以及可选绝对深度 $z_{\text{ref}} + x_3$ 相容的势能特征。正定质量保证动能二次型为正，标量势能则使保守广义力来自同一个能量函数。该写法把第 1.4 节中的功率账本转化为可学习模型的状态函数：动能由 (M_θ, p_r) 确定，势能由受状态契约限定的配置特征确定，耗散和外部广义力只通过后续动力学改变存储能量。

本文采用常质量矩阵参数化；参数化中直接学习正定逆质量 M_θ^{-1} ，再由其逆得到 M_θ 。具体地，令下三角因子 L_M 的对角元由正值映射保证，则 $M_\theta^{-1} = L_M L_M^\top \succ 0$ 。在这个设定下， $\partial H_\theta / \partial p_r = M_\theta^{-1} p_r = \nu_r$ ，因此相对速度和相对动量之间的配对关系在模型内部保持一致。若扩展为状态相关质量矩阵，则动量方程和能量导数还需包含额外的质量梯度项；本文的能量性质分析不覆盖该扩展情形。

1.5.3 势能诱导的保守广义力

势能 $V_\theta(q)$ 通过自动微分生成保守广义力。若势能包含绝对深度项，平动部分由受限的位置梯度给出；姿态部分由旋转矩阵行向量上的梯度与旋转运动学配对得到。若将 $R_{i:}$ 记为 R 的第 i 行， $\partial V_\theta / \partial R_{i:}$ 记为对应行梯度，则本文采用

$$f_\theta^V(q) = \begin{bmatrix} -R^\top \nabla_x V_\theta(q) \\ \sum_{i=1}^3 R_{i:} \times \frac{\partial V_\theta(q)}{\partial R_{i:}} \end{bmatrix}. \quad (1.39)$$

在静水条件下， $\dot{x} = R v_r$ 、 $\dot{R} = R \hat{\omega}$ ，式 (1.39) 满足

$$\nu_r^\top f_\theta^V(q) = -\frac{d}{dt} V_\theta(q). \quad (1.40)$$

该关系说明，保守分支不是任意的配置力网络，而是与机械存储函数中的同一个势能项配对。当势能不依赖某些相对位置分量时，相应梯度自然为零；因此式 (1.39) 的一般形式不意味着该模型学习任意全局位置势能。它也是式 (1.49) 中能量平衡成立的必要结构条件。

1.5.4 非保守广义力与执行器通道

除势能项外，AUV 的水动力阻尼、升力类横向作用、执行器作用和未建模效应共同进入非保守广义力。AUVHamNODE 将这部分写为

$$f_\theta^{\text{nc}} = -D_\theta(\xi) \nu_r + J_\theta(\xi) \nu_r + \tau_\theta(\nu_r, u_a, c_\tau), \quad (1.41)$$

其中 $D_\theta(\xi) \succeq 0$ 表示耗散矩阵， $J_\theta(\xi) = -J_\theta(\xi)^\top$ 表示斜对称零功率耦合矩阵， τ_θ 表示由执行器状态和上下文驱动的可学习广义力分支。这里用 ξ 表示耗散和零功率耦合分支的输入特征，用 c_τ 表示广义力分支的附加上下文，二者不必完全相同。在基本情形下 $\xi = \nu_r$ 且 c_τ 为空；在海流设置中， ξ 和 c_τ 可按模型配置包含体坐标海流速度

$v_c^b = R^\top v_c^n$ 或总体线速度 v_b 。这种记号区分避免把所有外源量都混入同一个未限定上下文，也避免把执行器广义力写成标准仿射输入矩阵。

这一分解对应三种不同的功率角色。耗散项满足 $\nu_r^\top [-D_\theta(\xi)\nu_r] \leq 0$ ，用于表达阻尼和速度相关能量耗散；斜对称项满足 $\nu_r^\top J_\theta(\xi)\nu_r = 0$ ，用于表达不改变机械存储能量的耦合或升力类作用；可学习广义力 τ_θ 则通过 $\nu_r^\top \tau_\theta$ 与机械核心交换功率。这里把由位姿 q 、相对动量 p_r 、机械存储函数 H_θ 、SE(3) 运动学、保守广义力 f_θ^V 、正定耗散项 $-D_\theta(\xi)\nu_r$ 以及斜对称零功率耦合项 $J_\theta(\xi)\nu_r$ 组成的力学子系统称为机械核心；其正式定义和能量性质在第 1.6 节给出。参数化时， D_θ 由正对角或 Cholesky 型因子构造为半正定矩阵， J_θ 由矩阵反对称化得到。这些构造继承了端口哈密顿和结构保持神经动力学中对耗散、互连和外部作用的角色划分 (van der Schaft and Jeltsema, 2014; van der Schaft, 2017; Desai et al., 2021; Eidnes et al., 2023)。由于真实水动力、舵桨作用和残差效应可能在统计上互相补偿，该分解只提供物理诱导的功能角色，不声称唯一恢复真实物理项。

执行器命令 u_c 不直接等同于实际广义力。实际执行器状态满足

$$\dot{u}_a = T_\theta^{-1}(u_c - u_a), \quad \dot{u}_c = 0, \quad (1.42)$$

其中 $T_\theta \in \mathbb{R}_{>0}^{m_0}$ 为正时间常数，由正值映射（如 softplus）保证其各分量为正。广义力分支以 u_a 而不是直接以 u_c 作为执行器状态输入，并按配置依赖 ν_r 、体坐标海流或总体速度等上下文。由此，控制命令到六自由度广义力之间的非线性映射由模型学习，但该映射仍作为外部广义力通道处理，而不是被改写成标准端口哈密顿形式中的固定输入矩阵。

海流和深度上下文在单个积分窗口内作为外源携带：

$$\dot{v}_c^n = 0, \quad \dot{z}_{\text{ref}} = 0. \quad (1.43)$$

其中 v_c^n 用于构造总体速度与相对水速度之间的转换，并可作为广义力或阻尼/零功率耦合分支的海流特征； z_{ref} 主要用于重构绝对深度并为势能分支提供深度上下文。它们没有独立储能函数，因此不属于机械存储函数 H_θ 的状态变量。

1.5.5 相对动量动力学

综合体坐标动量耦合、势能诱导的保守广义力和非保守广义力，模型先在相对动量变量上定义机械动力学：

$$\dot{p}_r = \text{ad}_{\nu_r}^* p_r + f_\theta^V(q) + f_\theta^{\text{nc}}, \quad (1.44)$$

令 $p_r = [p_v^\top, p_\omega^\top]^\top$ ， $\nu_r = [v_r^\top, \omega^\top]^\top$ 。式 (1.44) 中的体坐标动量耦合项取 $\mathfrak{se}(3)$ 上的余伴随 (coadjoint) 算子形式，其中相对速度满足 $\nu_r = \partial H_\theta / \partial p_r$ ，与体坐标刚体动量方程的标准约定一致 (Bullo and Lewis, 2004; Fossen, 2011)：

$$\text{ad}_{\nu_r}^* p_r = \begin{bmatrix} p_v \times \omega \\ p_\omega \times \omega + p_v \times v_r \end{bmatrix}. \quad (1.45)$$

该项对应体坐标动量的陀螺耦合结构，是由相对动量坐标和体坐标速度表示诱导的固定机械耦合项，并满足零功率性质 (Fossen, 2011, 2021):

$$\nu_r^\top \text{ad}_{\nu_r}^* p_r = v_r^\top (p_v \times \omega) + \omega^\top (p_\omega \times \omega + p_v \times v_r) = 0, \quad (1.46)$$

因而它只在体坐标动量分量之间重分配机械动量，不向机械存储函数注入或抽取净功率。这一点使式 (1.44) 与第 1.4 节所述 Fossen 型 Coriolis/向心结构保持同一功率角色。它与式 (1.41) 中的可学习斜对称项 $J_\theta(\xi)\nu_r$ 作用层次不同：前者来自动量坐标下的刚体/惯性耦合，后者用于表达数据诱导的升力或横向水动力类零功率作用。二者都具有零功率性质，但一个是模型坐标结构，另一个是可训练的非保守力分支。

由于模型态中显式保存的是 ν_r 而不是 p_r ，ODE 右端在构造 $\dot{p}_r$ 后再用正定逆质量将其映射回相对速度导数：

$$\dot{\nu}_r = M_\theta^{-1} \dot{p}_r. \quad (1.47)$$

将式 (1.35)、(1.47)、(1.42) 和 (1.43) 合并，可得增强状态上的完整连续时间模型：

$$\dot{y} = \left[\dot{x}, \text{vec}(\dot{R}), \dot{\nu}_r, T_\theta^{-1}(u_c - u_a), 0, 0, 0 \right]. \quad (1.48)$$

若不使用海流或深度上下文，式 (1.48) 中对应的零导数通道省略。该向量场是受控开放系统的模型：机械核心通过 D_θ 、 J_θ 和 τ_θ 组织功率关系，执行器和环境通道提供外源条件，输出评估再由 $\mathcal{T}_{m \rightarrow d}$ 回到数据空间。由此，第 3 节的速度契约、第 4 节的功率桥梁和本节的模型构造形成一致的定义链条。

1.6 结构化模型的能量性质与功率关系

本节分析第 1.5 节所构造模型的结构性能量与功率性质。这些性质是该模型机械部分的结构后果，而不是与主方法并列的新建模贡献：它们说明前述几何运动学、机械存储函数和非保守广义力分解在功率层面如何协同，从而为把端口哈密顿 (port-Hamiltonian) 语义限定在开放式机械子系统提供依据。为此，先界定承载这些性质的力学子系统，再逐项分析其功率角色，随后给出静水条件下的功率平衡命题与证明，最后说明海流、执行器、增强状态和数值积分对这些性质的适用边界。

1.6.1 六自由度机械子系统与存储函数

承载本节能量性质的对象是第 1.5 节模型中的六自由度力学部分，本文将其界定为机械核心。

定义 1.1 (AUVHamNODE 的机械核心). 在给定外部广义力 $\tau_\theta(\nu_r, u_a, c_\tau)$ 的条件下，AUVHamNODE 的机械核心指由配置 $q = (x, R)$ 、相对动量 p_r 、机械存储函数 $H_\theta(q, p_r)$ 、SE(3) 运动学、保守广义力 $f_\theta^V(q)$ 、正定耗散项 $-D_\theta(\xi)\nu_r$ 和斜对称零功率耦合项 $J_\theta(\xi)\nu_r$

组成的连续时间力学子系统。执行器状态 u_a 、命令 u_c 、海流 v_c^n 和深度上下文 z_{ref} 属于增强状态或外源上下文；它们可以影响广义力分支或速度转换，但不作为机械存储函数的独立储能变量。因而，本章的端口哈密顿性质只针对该机械核心的功率平衡，而不针对完整增强状态作闭合系统声明。

该机械核心对应第 1.5 节增强状态向量场 (1.48) 中的六自由度力学部分：位姿 $q = (x, R)$ 由 SE(3) 运动学 (1.35) 推进，相对动量 $p_r = M_\theta v_r$ （见式 (1.37)）与相对水速度 v_r 通过正定质量配对，机械存储函数 (1.38) 把第 1.4 节的功率账本写成状态函数。存储函数自然分解为动能 $K_\theta(p_r) = \frac{1}{2} p_r^\top M_\theta^{-1} p_r$ 与势能 $V_\theta(q)$ ：动能由常正定质量矩阵确定，势能由受第 1.3 节状态契约限定的配置特征确定。由于本文采用常质量参数化，相对速度满足 $\partial H_\theta / \partial p_r = M_\theta^{-1} p_r = v_r$ ，即存储函数对相对动量的梯度恰为功率配对所用的速度变量。执行器状态、命令、海流和深度通道虽然进入向量场 (1.48)，但它们在单个积分窗口内取零导数或按一阶滞后演化，没有独立储能函数，因而只作为机械核心的外源条件，而不计入存储函数 H_θ 。

1.6.2 耗散、零功率耦合与广义力功率

机械存储能量的变化由三类作用决定，它们在第 1.5 节已分别引入，本节归并为统一的功率角色分析。

第一类是不改变机械存储能量的零功率耦合，它在本文模型中有两个来源。其一是相对动量坐标诱导的余伴随耦合项，满足式 (1.46) 的零功率性质，只在体坐标动量分量之间重分配机械动量；其二是可学习斜对称分支 $J_\theta(\xi) v_r$ ，由反对称性给出 $v_r^\top J_\theta(\xi) v_r = 0$ ，用于表达升力或横向水动力类不做净功的耦合。二者功率角色相同，但前者是模型坐标结构、后者是可训练非保守分支，因此在结构消融中可分别处理。

第二类是耗散。由参数化直接保证的半正定性 $D_\theta(\xi) \succeq 0$ 给出 $v_r^\top [-D_\theta(\xi) v_r] \leq 0$ ，因此耗散项只能从机械存储中抽取能量，不能向其注入能量；这是把速度相关阻尼纳入结构约束而非任意残差项的关键性质。

第三类是保守广义力与可学习广义力。保守分支 (1.39) 与同一势能项配对并满足式 (1.40)，即 $v_r^\top f_\theta^V(q) = -dV_\theta(q)/dt$ ，故它在功率账本中只对应势能的可逆交换，而非独立能量源。可学习广义力 $\tau_\theta(v_r, u_a, c_\tau)$ 则通过 $v_r^\top \tau_\theta$ 与机械核心交换功率，是执行器驱动和未建模非保守效应进入机械核心的端口；其功率符号不受结构约束限定，正是这一端口把机械核心刻画为受控开放系统而非孤立保守系统。

1.6.3 静水条件下的功率平衡命题和证明

综合上述功率角色，可给出机械核心在静水条件下的能量平衡。

命题 1.1 (静水机械核心的能量平衡). 考虑无海流或静水条件 $v_c^n = 0$ 。假设连续时间精确流满足 $R(t) \in \text{SO}(3)$ 、 $M_\theta \succ 0$ 且 M_θ 不随状态变化、 $D_\theta(\xi) \succeq 0$ 、 $J_\theta(\xi) = -J_\theta(\xi)^\top$ ，

体坐标动量耦合项满足式 (1.45) 的零功率配对, 且保守广义力满足式 (1.40)。对于机械存储函数 (1.38) 和非保守力分解 (1.41), 机械核心满足

$$\dot{H}_\theta = -\nu_r^\top D_\theta(\xi)\nu_r + \nu_r^\top \tau_\theta(\nu_r, u_a, c_\tau). \quad (1.49)$$

特别地, 当 $\tau_\theta = 0$ 时, 机械核心的存储能量非增。

证明. 机械存储函数可分解为动能 $K_\theta = \frac{1}{2}p_r^\top M_\theta^{-1}p_r$ 和势能 $V_\theta(q)$ 。由于 M_θ 为常正定矩阵, 且 $\partial H_\theta / \partial p_r = M_\theta^{-1}p_r = \nu_r$, 动能导数为

$$\dot{K}_\theta = \nu_r^\top \dot{p}_r. \quad (1.50)$$

将式 (1.44) 代入, 得到

$$\dot{K}_\theta = \nu_r^\top \text{ad}_{\nu_r}^* p_r + \nu_r^\top f_\theta^V(q) + \nu_r^\top f_\theta^{\text{nc}}. \quad (1.51)$$

由式 (1.45) 的零功率性质, 第一项为零; 由势能功率配对式 (1.40), 第二项等于 $-\dot{V}_\theta$ 。因此

$$\dot{H}_\theta = \dot{K}_\theta + \dot{V}_\theta = \nu_r^\top f_\theta^{\text{nc}}. \quad (1.52)$$

再代入式 (1.41), 有

$$\nu_r^\top f_\theta^{\text{nc}} = -\nu_r^\top D_\theta(\xi)\nu_r + \nu_r^\top J_\theta(\xi)\nu_r + \nu_r^\top \tau_\theta(\nu_r, u_a, c_\tau). \quad (1.53)$$

由于 $J_\theta(\xi) = -J_\theta(\xi)^\top$, $\nu_r^\top J_\theta(\xi)\nu_r = 0$, 从而得到式 (1.49)。又因 $D_\theta(\xi) \succeq 0$, 当 $\tau_\theta = 0$ 时有 $\dot{H}_\theta \leq 0$ 。□

该命题表明, 在限定条件下机械核心的净能量变化只由耗散消耗 $-\nu_r^\top D_\theta(\xi)\nu_r$ 和外部广义力端口功率 $\nu_r^\top \tau_\theta$ 决定, 零功率耦合和保守分支均不改变这一平衡。它把第 1.4 节 Fossen 型功率结构在结构化学习模型上的对应关系固定为可检验的连续时间性质, 也解释了为何后续评估要把能量诊断作为结构是否按预期工作的内部证据。

1.6.4 海流、执行器与增强状态的适用范围

命题 1.1 的成立依赖若干结构与情形假设, 明确其适用边界对避免过度声称十分重要。

其一, 命题针对开放式机械核心, 而非完整增强系统。执行器状态、命令、海流和深度上下文属于增强状态或外源上下文, 可条件化广义力分支或参与速度转换, 但不作为机械存储函数中的独立储能变量; 因此本章不声称完整航行器-执行器-环境系统构成严格闭合的端口哈密顿系统。

其二, 海流条件下能量导数可能出现附加项。命题以静水条件 $v_c^n = 0$ 为前提; 当存在外源流场且势能依赖绝对位置或深度时, 外源平移会引入额外功率项, 使等式右

端不再只含耗散与广义力端口功率。本文因此不把海流视为带独立储能的闭合哈密顿环境子系统，而仅作为影响速度契约和广义力分支的外源条件。

其三，执行器与外源上下文通过广义力端口而非储能进入机械核心。命令到广义力的非线性映射由 τ_θ 经一阶执行器滞后 (1.42) 学习得到，但它仍作为外部广义力端口处理，而不等同于标准端口哈密顿形式中的固定输入矩阵 $G(q)u$ 。

其四，命题是连续时间精确流的性质，而非普通数值积分的保证。能量平衡在连续时间向量场层面成立；若采用通用显式 ODE 求解器，离散积分仍可能在能量与 $SO(3)$ 正交性上产生偏差，因此评估需同时报告能量和姿态结构诊断，而不能假设普通求解器严格保持上述等式或严格保持 $SO(3)$ 。

其五，本节能量性质限定为常质量参数化。若扩展为状态相关质量矩阵，动量方程与能量导数将出现额外的质量梯度项，本节命题不覆盖该情形（见式 (1.37) 后关于常质量参数化的说明）。

1.7 训练目标、基线体系与验证协议

1.7.1 结构保持参数化

神经参数化服务于上述理论对象，并将部分结构性质直接写入可训练函数类。逆质量矩阵采用 Cholesky 型参数化：令 L_M 为下三角矩阵，其对角元由 softplus 映射保证为正，则

$$M_\theta^{-1} = L_M L_M^\top \succ 0, \quad M_\theta = (M_\theta^{-1})^{-1}. \quad (1.54)$$

势能分支输出标量 $V_\theta(q)$ ，实际实现中可使用重力方向、姿态特征和可选绝对深度上下文作为输入。耗散分支在完整形式下输出下三角因子 $L_D(\xi)$ ，并构造

$$D_\theta(\xi) = L_D(\xi) L_D(\xi)^\top \succeq 0; \quad (1.55)$$

对角阻尼消融则使用正对角元素构造 $\text{diag}(d_\theta(\xi))$ 。斜对称分支输出矩阵上三角参数并反对称化：

$$J_\theta(\xi) = A_\theta(\xi) - A_\theta(\xi)^\top. \quad (1.56)$$

可学习广义力分支 τ_θ 接收执行器状态、相对速度和可选海流特征，用于表达执行器驱动和其他无法解析闭合的非保守广义力。

上述参数化将正定性、半正定性和斜对称性直接作用于可训练函数类。由参数化直接保证的性质构成模型结构约束；由数值积分、状态转换和数据分布共同决定的性质，则通过训练目标和评估指标进行检验。

表 1.2: 理论对象与可训练参数化的对应关系

理论对象	参数化目标	结构作用
M_θ^{-1}	$L_M L_M^\top$ 正定逆质量矩阵	保证动能二次型正定，定义相对动量和速度映射。
$V_\theta(q)$	标量势能网络与线性先验	使保守广义力来自同一能量函数。
$D_\theta(\xi)$	满矩阵正定阻尼或对角正阻尼	保证耗散项不向机械核心注入能量。
$J_\theta(\xi)$	反对称化耦合矩阵	表达零功率横向或升力类耦合。
$\tau_\theta(\nu_r, u_a, c_\tau)$	执行器状态和上下文驱动的广义力网络	表达执行器驱动和未建模非保守效应；不等同于标准 $G(q)u$ 端口矩阵。
T_θ	softplus 正时间常数	表达命令到实际执行器状态的一阶滞后。
$\mathcal{T}_{d \rightarrow m}, \mathcal{T}_{m \rightarrow d}$	数据/模型状态转换	维持输出空间和内部动力学变量的一致性。

1.7.2 控制块训练目标

训练数据由控制块序列组成。在单个控制块内，控制命令和外源上下文保持分段常值，模型从块初值出发积分生成预测轨迹。预测过程为

$$y_0 = \mathcal{T}_{d \rightarrow m}(s_0), \quad \hat{y}(t_i) = \Phi_\theta(t_i; t_0, y_0, u_c, c), \quad \hat{s}_i = \mathcal{T}_{m \rightarrow d}(\hat{y}(t_i)), \quad (1.57)$$

其中 Φ_θ 表示由神经常微分方程积分得到的流映射。训练时，目标轨迹也转换到模型态 $y_i = \mathcal{T}_{d \rightarrow m}(s_i)$ ，使有海流样本的速度损失作用于相对水速度表示；位置、姿态和执行器状态在数据态与模型态中保持同一数值。一个典型加权训练目标可写为

$$\mathcal{L} = \sum_i \lambda_x \|\hat{x}_i - x_i\|^2 + \lambda_R d_{\text{SO}(3)}(\hat{R}_i, R_i)^2 + \lambda_\nu \|\hat{\nu}_{r,i} - \nu_{r,i}\|^2 + \lambda_a \|\hat{u}_{a,i} - u_{a,i}\|^2 + \lambda_{\text{SO}} \mathcal{L}_{\text{SO}(3)}, \quad (1.58)$$

其中 $d_{\text{SO}(3)}$ 为旋转测地距离， $\mathcal{L}_{\text{SO}(3)}$ 为旋转矩阵正交性和行列式正则项。评估和报告时，预测轨迹再通过 $\mathcal{T}_{m \rightarrow d}$ 回到数据态，因此终端位置、姿态和总体速度等可观测指标仍在数据空间解释。

1.7.3 长期递推与证据口径

评估协议的目标不是只比较局部拟合误差，而是检验结构约束是否改善长期递推稳定性、初值扰动鲁棒性和内部物理一致性。数据来源采用受控仿真生成的 AUV 轨迹块，可区分无海流和有海流设置；有海流数据使用式 (1.22) 明确总体速度与相对水

速度的转换关系。训练设置至少区分干净初值训练 (clean training) 与基于噪声配置的初值扰动训练 (profile-based noisy initial-condition training), 后者通过预热、斜坡增长和干净样本混合比例控制训练噪声强度。

长期递推预测将上一控制块的预测末状态作为下一控制块初值, 用于检验误差累积、姿态漂移、速度发散和数值失败。该任务的首要指标是完成率 (completion rate)、到达目标时域完成率 (completed-to-horizon rate) 和失败原因 (failure reason), 因为只有模型完成目标时域后, 终端误差才具有可比性。失败原因应区分预测发散、ODE 求解失败、NaN/Inf、速度或深度约束违反, 以及地面真值递推任务自身失败等情形。

在完成目标时域的样本上, 主要误差指标包括终端位置误差、深度误差、旋转测地误差、总体线速度误差、总体角速度误差和误差增长曲线; 可进一步报告中位数、第 90 百分位或第 95 百分位轨迹误差以展示长期误差累积。相对速度误差属于模型空间诊断, 用于解释水动力建模变量是否一致, 不替代数据空间总体速度指标。能量、SO(3) 行列式误差和正交性误差用于解释内部结构是否按预期工作, 也不替代外部任务误差。

可复现实验报告需要同时给出数据生成配置、训练/验证/测试划分、随机种子、控制块长度、采样间隔、积分器类型、误差容差、长期递推时域、失败判据、噪声配置和代码环境记录。结果进入主结论前应满足一致的数据协议、评估口径和代码环境记录。目录化结果可优先使用规范化长期递推结果视图生成表格和图, 但规范化视图不自动等于当前论文证据; 引用具体数值时还需检查证据状态。标记为证据过期、需要复核或仅具有协议敏感性分析含义的结果, 只能用于讨论证据边界、协议敏感性或后续工作, 不能作为主性能排序的无条件依据。

1.7.4 基线模型与结构消融链条

模型比较链条覆盖非结构化 full-state 模型、SE(3) 加速度模型、SE(3) 动量模型、端口哈密顿风格结构模型和 AUVHamNODE 完整模型。该链条按结构约束递增组织, 用于分离几何运动学、动量坐标、能量结构和非保守力分解各自的作用: 非结构化模型检验缺少几何与能量结构时的长期递推风险, 几何与动量基线分别隔离显式位姿运动学和动量坐标的贡献, 端口哈密顿风格基线检验机械存储核心和不同广义力组织方式的作用, 完整模型则同时包含速度契约、SE(3) 运动学、机械存储、 $D_\theta/J_\theta/\tau_\theta$ 分解和执行器滞后。表 1.3 汇总各模型类别在证据链中的角色。

1.7.5 结构消融设置

结构消融在完整模型上逐项移除或弱化某一结构组件, 用于检验第 1.6 节中各结构性质是否在长期递推中确有作用。每个消融对象对应一个明确的结构假设:

- 质量先验消融 (No Mass Prior) 放松正定常质量矩阵的结构约束, 检验式 (1.37) 的质量先验对动量-速度配对和长期稳定性是否必要。

表 1.3: 模型比较与结构消融的证据角色

模型类别	代表模型	证据作用
非结构化状态模型	Full-State Black-Box	检验缺少几何与能量结构时的长期递推风险。
几何基线	SE(3) Acceleration Black-Box	隔离显式位姿运动学对姿态和位置预测的作用。
动量基线	SE(3) Momentum Black-Box	隔离动量坐标和质量矩阵对速度预测的作用。
结构化 pH 基线	pH NODE Merged Force, pH NODE q-Force	检验能量核心和不同广义力组织方式的贡献。
完整模型	AUVHamNODE / pH NODE Full	同时包含速度契约、SE(3) 运动学、机械存储、 $D/J/\tau$ 分解和执行器滞后。
消融模型	No Mass Prior, Diagonal Damping, No Lift, B(u) Only	分别检验质量先验、耦合阻尼、零功率耦合和执行器条件化的必要性。

- 对角阻尼消融 (Diagonal Damping) 将完整耦合耗散矩阵 $D_\theta(\xi)$ 退化为对角形式, 检验耦合阻尼相对独立通道阻尼的价值。
- 零功率耦合消融 (No Lift) 移除斜对称分支 $J_\theta(\xi)\nu_r$, 检验升力或横向水动力类零功率耦合对相对速度预测的结构贡献。
- 广义力条件化消融 (B(u) Only) 把广义力分支 τ_θ 收缩为仅由执行器输入驱动, 检验其对相对速度和海流上下文条件化的必要性。

保守与非保守广义力的组织粒度则由表 1.3 中的结构化端口哈密顿基线 (pH NODE Merged Force、pH NODE q-Force) 进一步对照。上述消融与基线链条共同构成结构证据的来源: 基线链条说明从黑箱到结构化模型的整体差异, 结构消融说明完整模型内部各结构组件的边际作用。各消融的长期递推结果与排序在第 1.8 节按 current evidence 主表给出, 本节只固定消融设计及其检验目标, 不预先给出性能结论。

1.8 实验结果与结构证据分析

1.9 讨论

本章方法的端口哈密顿性质限定于开放式机械核心及其功率平衡, 不等同于完整航行器-执行器-环境系统的严格闭合端口哈密顿化。执行器状态、命令输入、海流和

深度上下文属于增强状态或外源上下文，它们可以条件化广义力分支或参与速度转换，但不作为机械存储函数中的独立储能变量。因此，本章的理论声明应理解为对结构化连续时间向量场和机械核心功率平衡关系的约束，而不是对完整增强系统的闭合能量守恒声明。

连续时间向量场与 $SO(3)$ 切空间相容，但若数值实现采用普通 ODE 求解器，仍可能产生离散积分层面的正交性误差。因而，姿态预测不能只报告欧氏矩阵误差，还需要报告旋转测地误差、行列式偏差和正交性诊断。若后续采用严格李群积分器或投影积分方案，可进一步区分模型结构误差和数值积分误差。

非保守力分解提供结构诱导的功能角色，不保证唯一辨识真实水动力项。正定耗散、斜对称零功率耦合和可学习广义力分支可以提高假设空间的可解释性，但不同分支之间仍可能存在统计补偿。结构消融和内部物理诊断只能说明这些结构在给定数据协议和模型族下的作用，不能单独证明各神经分支逐项恢复了真实物理机理。

当前实验验证对象是受控仿真生成的数据分布。仿真数据能够提供可重复、可消融和可诊断的证据环境，但不等同于真实海试条件下的泛化验证。真实海域中的传感器偏差、海况变化、平台参数误差、执行器非理想性和未建模环境扰动仍需要后续实验支持。基于噪声配置的初值扰动训练也应作为协议相关的鲁棒性检验，而不应无条件推广为所有扰动条件下的性能保证。

1.10 本章小结

本章从 AUV 长期轨迹预测中的几何、能量、执行器和海流建模需求出发，提出一种结构化神经动力学建模方法，并将其简称为 AUVHamNODE。该方法以 Neural ODE 表达连续时间预测，以 Fossen 型动力学和端口哈密顿思想组织机械存储、耗散、零功率耦合和外部广义力，并以海流条件下的数据态-模型态转换维持总体速度与相对水速度的一致性。

本章给出了该模型的状态表示、速度约定、 $SE(3)$ 运动学、相对动量动力学、非保守广义力分解、执行器滞后和外源通道，并证明了静水机械核心在限定条件下的能量平衡性质。训练与验证协议进一步将结构保持参数化、控制块损失、长期递推、结构消融、初值扰动和物理诊断联系起来，用于检验结构约束是否在长期预测中发挥作用。上述内容构成本章后续实验分析和证据边界讨论的理论基础。

参考文献

- Faheem Ahmed, Xianbo Xiang, Chaicheng Jiang, Gong Xiang, and Shaolong Yang. Survey on traditional and AI based estimation techniques for hydrodynamic coefficients of autonomous underwater vehicle. *Ocean Engineering*, 268:113300, 2023. doi: 10.1016/j.oceaneng.2022.113300.
- Wilmer Ariza Ramirez, Juš Kocijan, Zhi Quan Leong, Hung Duc Nguyen, and Shantha Gamini Jayasinghe. Dynamic system identification of underwater vehicles using multi-output gaussian processes. *Machine Intelligence Research*, 18(5):681–693, 2021. doi: 10.1007/s11633-021-1308-x.
- Vladimir I. Arnold. *Mathematical Methods of Classical Mechanics*, volume 60 of *Graduate Texts in Mathematics*. Springer, 2 edition, 1989. doi: 10.1007/978-1-4757-1693-1.
- Francesco Bullo and Andrew D. Lewis. *Geometric Control of Mechanical Systems*. Springer, 2004. doi: 10.1007/978-1-4899-7276-7.
- Massimo Caccia, Giovanni Indiveri, and Gianmarco Veruggio. Modeling and identification of open-frame variable configuration unmanned underwater vehicles. *IEEE Journal of Oceanic Engineering*, 25(2):227–240, 2000. doi: 10.1109/48.838986.
- Ricky T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, and David K. Duvenaud. Neural ordinary differential equations. In *Advances in Neural Information Processing Systems*, volume 31, 2018.
- Kamel Cherifi. An overview on recent machine learning techniques for port Hamiltonian systems. *Physica D: Nonlinear Phenomena*, 411:132620, 2020. doi: 10.1016/j.physd.2020.132620.
- Miles Cranmer, Sam Greydanus, Stephan Hoyer, Peter Battaglia, David Spergel, and Shirley Ho. Lagrangian neural networks, 2020.
- Shaan Desai, Marios Mattheakis, David Sondak, Pavlos Protopapas, and Stephen J. Roberts. Port-Hamiltonian neural networks for learning explicit time-dependent dy-

- namical systems. *Physical Review E*, 104(3):034312, 2021. doi: 10.1103/PhysRevE.104.034312.
- Thai Duong and Nikolay Atanasov. Hamiltonian-based neural ODE networks on the $SE(3)$ manifold for dynamics learning and control. In *Proceedings of Robotics: Science and Systems (RSS)*, volume XVII, 2021. doi: 10.15607/RSS.2021.XVII.086.
- Thai Duong, Abdullah Altawaitan, Jason Stanley, and Nikolay Atanasov. Port-Hamiltonian neural ODE networks on Lie groups for robot dynamics learning and control. *IEEE Transactions on Robotics*, 40:3695–3715, 2024. doi: 10.1109/TRO.2024.3428433.
- Sølve Eidnes, Alexander J. Stasik, Christian Sterud, Signe Riemer-Sørensen, and Eivind Bøhn. Pseudo-Hamiltonian neural networks with state-dependent external forces. *Physica D: Nonlinear Phenomena*, 446:133673, 2023. doi: 10.1016/j.physd.2023.133673.
- Melek Ertogan and Philip A. Wilson. Modelling using neural networks and dynamic position control for unmanned underwater vehicles. *Journal of Eta Maritime Science*, 12(1):64–73, 2024. doi: 10.4274/jems.2024.46514.
- Xinyu Fei, Lu Wang, Ruiheng Liu, Shipang Qian, Jiaxuan Song, Suohang Zhang, Yanhu Chen, and Canjun Yang. A physics-guided hybrid network for robust hydrodynamic parameter identification of UUVs under lumped disturbances. *Journal of Marine Science and Engineering*, 14(5):434, 2026. doi: 10.3390/jmse14050434.
- Marc Finzi, Ke Alexander Wang, and Andrew Gordon Wilson. Simplifying Hamiltonian and Lagrangian neural networks via explicit constraints. In *Advances in Neural Information Processing Systems*, volume 33, 2020.
- Thor I. Fossen. *Handbook of Marine Craft Hydrodynamics and Motion Control*. John Wiley & Sons, 2011. doi: 10.1002/9781119994138.
- Thor I. Fossen. *Handbook of Marine Craft Hydrodynamics and Motion Control*. John Wiley & Sons, 2 edition, 2021. doi: 10.1002/9781119575054.
- Samuel Greydanus, Misko Dzamba, and Jason Yosinski. Hamiltonian neural networks. In *Advances in Neural Information Processing Systems*, volume 32, 2019.
- Ernst Hairer, Christian Lubich, and Gerhard Wanner. *Geometric Numerical Integration: Structure-Preserving Algorithms for Ordinary Differential Equations*. Springer, 2 edition, 2006. doi: 10.1007/3-540-30666-8.

- Arieh Iserles, Hans Z. Munthe-Kaas, Syvert P. Nørsett, and Antonella Zanna. Lie-group methods. *Acta Numerica*, 9:215–365, 2000.
- George Em Karniadakis, Ioannis G. Kevrekidis, Lu Lu, Paris Perdikaris, Sifan Wang, and Liu Yang. Physics-informed machine learning. *Nature Reviews Physics*, 3:422–440, 2021. doi: 10.1038/s42254-021-00314-5.
- Patrick Kidger, James Morrill, James Foster, and Terry Lyons. Neural controlled differential equations for irregular time series. In *Advances in Neural Information Processing Systems*, volume 33, 2020.
- Michael Lutter, Christian Ritter, and Jan Peters. Deep Lagrangian networks: Using physics as model prior for deep learning. In *International Conference on Learning Representations*, 2019.
- Xan Macatangay, Sargon A. Gabriel, Reza Hoseinnezhad, Anthony Fowler, and Alireza Bab-Hadiashar. Machine learning for modeling underwater vehicle dynamics: Overview and insights. *IEEE Access*, 12:139486–139504, 2024. doi: 10.1109/ACCESS.2024.3464644.
- Hans Munthe-Kaas. High order Runge–Kutta methods on manifolds. *Applied Numerical Mathematics*, 29(1):115–127, 1999.
- Jyoti Prakash Panda, Arindam Mitra, and Hari V. Warrior. A review on the hydrodynamic characteristics of autonomous underwater vehicles. *Proceedings of the Institution of Mechanical Engineers, Part M: Journal of Engineering for the Maritime Environment*, 235(1):15–29, 2021. doi: 10.1177/1475090220936896.
- A. B. Phillips, S. R. Turnock, and M. Furlong. The use of computational fluid dynamics to aid cost-effective hydrodynamic design of autonomous underwater vehicles. *Proceedings of the Institution of Mechanical Engineers, Part M: Journal of Engineering for the Maritime Environment*, 224(4):239–254, 2010. doi: 10.1243/14750902JEME199.
- Timothy Prestero. Verification of a six-degree of freedom simulation model for the REMUS autonomous underwater vehicle. M.s. thesis, Massachusetts Institute of Technology and Woods Hole Oceanographic Institution, 2001.
- Christopher Rackauckas, Yingbo Ma, Julius Martensen, Collin Warner, Kirill Zubov, Rohit Supekar, Dominic Skinner, Ali Ramadhan, and Alan Edelman. Universal differential equations for scientific machine learning, 2020.

- Maziar Raissi, Paris Perdikaris, and George E. Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019. doi: 10.1016/j.jcp.2018.10.045.
- Alok Sahoo, Santosh Kumar Dwivedy, and P. S. Robi. Advancements in the field of autonomous underwater vehicle. *Ocean Engineering*, 181:145–160, 2019. doi: 10.1016/j.oceaneng.2019.04.011.
- Shanshan Song, Jun Liu, Jiani Guo, Jun Wang, Yanxin Xie, and Jun-Hong Cui. Neural-network-based AUV navigation for fast-changing environments. *IEEE Internet of Things Journal*, 7(10):9773–9783, 2020. doi: 10.1109/JIOT.2020.2988313.
- Pepijn W. J. van de Ven, Tor A. Johansen, Asgeir J. Sørensen, Colin Flanagan, and Daniel Toal. Neural network augmented identification of underwater vehicle models. *Control Engineering Practice*, 15(6):715–725, 2007. doi: 10.1016/j.conengprac.2005.11.004.
- Arjan van der Schaft. *L₂-Gain and Passivity Techniques in Nonlinear Control*. Springer, 3 edition, 2017. doi: 10.1007/978-3-319-49992-5.
- Arjan J. van der Schaft and Dimitri Jeltsema. Port-hamiltonian systems theory: An introductory overview. *Foundations and Trends in Systems and Control*, 1(2–3):173–378, 2014. doi: 10.1561/26000000002.
- Russell B. Wynn, Veerle A. I. Huvenne, Tim P. Le Bas, Bramley J. Murton, Douglas P. Connelly, Brian J. Bett, Henry A. Ruhl, Kirsty J. Morris, Jeff Peakall, Daniel R. Parsons, Esther J. Sumner, Stephen E. Darby, Robert M. Dorrell, and James E. Hunt. Autonomous underwater vehicles (AUVs): Their past, present and future contributions to the advancement of marine geoscience. *Marine Geology*, 352:451–468, 2014. doi: 10.1016/j.margeo.2014.03.012.
- Feng Xu, Zao-Jian Zou, Jian-Chuan Yin, and Jian Cao. Identification modeling of underwater vehicles’ nonlinear dynamics based on support vector machines. *Ocean Engineering*, 67:68–76, 2013. doi: 10.1016/j.oceaneng.2013.02.006.
- Jieen Yao, Junzheng Yang, Chenghao Zhang, Jing Zhang, and Tianchi Zhang. Autonomous underwater vehicle trajectory prediction with the nonlinear kepler optimization algorithm–bidirectional long short-term memory–time-variable attention model. *Journal of Marine Science and Engineering*, 12(7):1115, 2024. doi: 10.3390/jmse12071115.

- Yifeng Zhao, Zhiqiang Hu, Weifeng Du, Lingbo Geng, and Yi Yang. Research on modeling method of autonomous underwater vehicle based on a physics-informed neural network. *Journal of Marine Science and Engineering*, 12(5):801, 2024. doi: 10.3390/jmse12050801.
- Yaofeng Desmond Zhong, Biswadip Dey, and Amit Chakraborty. Dissipative SymODEN: Encoding Hamiltonian dynamics with dissipation and control into deep learning, 2020a.
- Yaofeng Desmond Zhong, Biswadip Dey, and Amit Chakraborty. Symplectic ODE-Net: Learning Hamiltonian dynamics with control. In *International Conference on Learning Representations*, 2020b.